```
from operator import itemgetter
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
import numpy as np
import math
from sklearn.model_selection import train_test_split

from enum import Enum
class PredictionType(Enum):
    CLASSIFICATION = 1
    REGRESSION = 2

class SimpleKNN:

    def fit(self, X_train: np.matrix, y_train: np.ndarray):
        """
        Метод обучения, который фактически не учится,
        а только запоминает обучающую выборку.
        Входные параметры:
        X_train - обучающая выборка (матрица объект-признак)
        y_train - обучающая выборка (вектор целевого признака)
        Возвращаемое значение: нет
        """
        #Сохраняем параметры в переменных класса
        self._X_train = X_train
        self._y_train = y_train

    def eucl_dist(self, p: np.ndarray, q: np.ndarray) -> float:
        """
        Вычисление Евклидова расстояния -
https://en.wikipedia.org/wiki/Euclidean_distance
        Входные параметры:
        p, q - вектора в n-мерном пространстве признаков
        """
        return math.sqrt(sum([(pi - qi) ** 2 for pi, qi in zip (p,
q)]))


    def predict_for_single_object(self, K: int, \
                prediction_type: PredictionType, \
                X_o: np.ndarray, \
                verbose = True) -> np.ndarray:
        """
        Метод предсказания для одного объекта.
        Входные параметры:
        K - гиперпараметр, количество соседей
        prediction_type - классификация или регрессия
        X_o - строка матрицы объект-признак, соответствующая объекту
        verbose - флаг детального вывода
        Возвращаемое значение: предсказанное значение целевого
признака
```

```
        """
        # список соседей
        neighbors_list = []
        # *** Находим ближайшие точки ***
        # Перебираем все точки обучающей выборки
        for i in range(self._X_train.shape[0]):
            # получаем текущую точку
            data_train_current_x = [x for x in
self._X_train[['high','low']].iloc[i]]
            # и значение ее y
            data_train_current_y = self._y_train[i]
            # вычисляем расстояние
            dist = self.eucl_dist(X_o, data_train_current_x)
            # сохраняем в список соседей
            temp_res = (data_train_current_y, dist,
data_train_current_x)
            neighbors_list.append(temp_res)
        # *** сортируем список соседей по возрастанию расстояния ***
        # в кортеже элементы следуют в порядке (0,1,2), сортируем по
первому элементу
        neighbors_list_sorted = sorted(neighbors_list,
key=itemgetter(1))
        if verbose:
            print()
            print('************************************')
            print('Проверяемая точка: ', X_o)
            print('************************************')
            print('Вывод отсортированного списка соседей:')
            dist_list = []
            for cur_y, cur_dist, temp_x_1_2 in neighbors_list_sorted:
                temp_x1, temp_x2 = temp_x_1_2
                print('X1={0}, X2={1}, y={2},
расстояние={3:.2f}'.format(temp_x1, temp_x2, cur_y, cur_dist))
                dist_list.append(cur_dist)
            print()
            print('Вывод расстояния для отсортированного списка
соседей:')
            plt.plot(dist_list)
            plt.show()
        # Оставим только K ближайших соседей
        K_neighbors_list_sorted = neighbors_list_sorted[:K]
        if verbose:
            print('Вывод K ближайших соседей:')
            x1_list = []
            x2_list = []
            for cur_y, cur_dist, temp_x_1_2 in
K_neighbors_list_sorted:
                temp_x1, temp_x2 = temp_x_1_2
                x1_list.append(temp_x1)
                x2_list.append(temp_x2)
```

```
                print('X1={0}, X2={1}, y={2},
расстояние={3:.2f}'.format(temp_x1, temp_x2, cur_y, cur_dist))
            print()
            print('Визуализация K ближайших соседей:')
            plt.plot(self._X_train['high'], self._X_train['low'],
'b.', \
                     x1_list, x2_list,  'g*', \
                    [X_o[0]], [X_o[1]], 'ro')
            plt.show()
        # Результат - классификация или регрессия
        if prediction_type == PredictionType.REGRESSION:
            # используем numpy для вычисления среднего значения
            arr = np.array([x for x,_,_ in K_neighbors_list_sorted])
            # возвращаем среднее значение
            return np.mean(arr)
        elif prediction_type == PredictionType.CLASSIFICATION:
            k_y_list = [y for y,_,_ in K_neighbors_list_sorted]
            # группируем с количеством метки классов,
            # соответствующие K ближайшим соседям
            k_y_list_grouped_temp = np.unique(k_y_list,
return_counts=True)
            k_y_list_grouped = [[key, cnt] for key, cnt in
zip(k_y_list_grouped_temp[0], k_y_list_grouped_temp[1])]
            # сортируем по количеству по убыванию
            k_y_list_grouped_sorted = sorted(k_y_list_grouped,
key=itemgetter(1), reverse=True)
            if verbose:
                print('Классы, соответствующие K ближайшим соседям:')
                for i in k_y_list_grouped_sorted:
                    print('класс={0}, количество
элементов={1}'.format(i[0], i[1]))
            # возвращаев метку класса из первой строки
отсортированного массива
            # то есть того класса, к которому принадлежит наибольшее
количество соседей
            return k_y_list_grouped_sorted[0][0]
        else:
            raise Exception('Неизвестный тип предсказания')


    def predict(self, K: int, \
                prediction_type: PredictionType, \
                X_test: np.matrix,
                verbose = True) -> np.ndarray:
        """
        Метод предсказания.
        Входные параметры:
        K - гиперпараметр, количество соседей
        prediction_type - классификация или регрессия
        X_test - тестовая выборка (матрица объект-признак)
```

```
        Возвращаемое значение: предсказанный вектор целевого признака
        """
        # Перебираем все точки тестовой выборки
        test_data_temp = []
        for i in range(X_test.shape[0]):
            # получаем текущую точку
            data_test_current_x = [x for x in X_test.iloc[i]]
            test_data_temp.append(data_test_current_x)
        return [self.predict_for_single_object(K=K, \
                prediction_type=prediction_type, \
                X_o=i, verbose=verbose) for i in test_data_temp]
```

```
import pandas as pd

data_train = pd.read_csv('WIKI_PRICES_train.csv', sep=",")

data_train
```

```
   ticker        date   open   high    low  close      volume  ex-
dividend  \
0       A  1999-11-18  45.50  50.00  40.00  44.00  44739900.0
0.0
1       A  1999-11-19  42.94  43.00  39.81  40.38  10897100.0
0.0
2       A  1999-11-22  41.31  44.00  40.06  44.00   4705200.0
0.0
3       A  1999-11-23  42.50  43.63  40.25  40.25   4274400.0
0.0
4       A  1999-11-24  40.13  41.94  40.00  41.06   3464400.0
0.0
5       A  1999-11-26  40.88  41.50  40.75  41.19   1237100.0
0.0
6       A  1999-11-29  41.00  42.44  40.56  42.13   2914700.0
0.0
7       A  1999-11-30  42.00  42.94  40.94  42.19   3083000.0
0.0
8       A  1999-12-01  42.19  43.44  41.88  42.94   2115400.0
0.0
9       A  1999-12-02  43.75  45.00  43.19  44.13   2195900.0
0.0
10      A  1999-12-03  44.94  45.69  44.31  44.50   2175700.0
0.0
11      A  1999-12-06  45.25  46.44  45.19  45.75   1610000.0
0.0
12      A  1999-12-07  45.75  46.00  44.31  45.25   1585100.0
0.0
13      A  1999-12-08  45.25  45.63  44.81  45.19   1350400.0
0.0
14      A  1999-12-09  45.25  45.94  45.25  45.81   1451400.0
0.0
```

```
15      A  1999-12-10  45.69  45.94  44.75  44.75   1190800.0
0.0
16      A  1999-12-13  45.50  46.25  44.38  45.50   2875900.0
0.0
17      A  1999-12-14  45.38  45.38  42.06  43.00   1665900.0
0.0
18      A  1999-12-15  42.00  42.31  41.00  41.69   2087100.0
0.0
19      A  1999-12-16  42.00  48.00  42.00  47.25   1848300.0
0.0

    split_ratio   adj_open   adj_high    adj_low  adj_close
adj_volume
0           1.0  31.041951  34.112034  27.289627  30.018590
44739900.0
1           1.0  29.295415  29.336350  27.160002  27.548879
10897100.0
2           1.0  28.183363  30.018590  27.330562  30.018590
4705200.0
3           1.0  28.995229  29.766161  27.460188  27.460188
4274400.0
4           1.0  27.378319  28.613174  27.289627  28.012803
3464400.0
5           1.0  27.889999  28.312988  27.801308  28.101494
1237100.0
6           1.0  27.971868  28.954295  27.671682  28.742800
2914700.0
7           1.0  28.654109  29.295415  27.930934  28.783735
3083000.0
8           1.0  28.783735  29.636535  28.572240  29.295415
2115400.0
9           1.0  29.848030  30.700831  29.465975  30.107281
2195900.0
10          1.0  30.659896  31.171577  30.230085  30.359711
2175700.0
11          1.0  30.871391  31.683257  30.830457  31.212511
1610000.0
12          1.0  31.212511  31.383072  30.230085  30.871391
1585100.0
13          1.0  30.871391  31.130643  30.571205  30.830457
1350400.0
14          1.0  30.871391  31.342137  30.871391  31.253446
1451400.0
15          1.0  31.171577  31.342137  30.530271  30.530271
1190800.0
16          1.0  31.041951  31.553632  30.277842  31.041951
2875900.0
17          1.0  30.960082  30.960082  28.695043  29.336350
1665900.0
18          1.0  28.654109  28.865603  27.971868  28.442614
```

```
2087100.0
19          1.0  28.654109  32.747553  28.654109  32.235872
1848300.0
```

```python
def regr_to_class(high: float) -> str:
    if high<43:
        result = 'A'
    elif high<46:
        result = 'B'
    elif high<50:
        result = 'C'
    else:
        result = 'D'
    return result

# формирование второго целевого признака для классификации
data_train['y_clas'] = \
data_train.apply(lambda row: regr_to_class(row['high']),axis=1)

data_train
```

```
   ticker        date   open   high    low  close      volume  ex-
dividend  \
0       A  1999-11-18  45.50  50.00  40.00  44.00  44739900.0
0.0
1       A  1999-11-19  42.94  43.00  39.81  40.38  10897100.0
0.0
2       A  1999-11-22  41.31  44.00  40.06  44.00   4705200.0
0.0
3       A  1999-11-23  42.50  43.63  40.25  40.25   4274400.0
0.0
4       A  1999-11-24  40.13  41.94  40.00  41.06   3464400.0
0.0
5       A  1999-11-26  40.88  41.50  40.75  41.19   1237100.0
0.0
6       A  1999-11-29  41.00  42.44  40.56  42.13   2914700.0
0.0
7       A  1999-11-30  42.00  42.94  40.94  42.19   3083000.0
0.0
8       A  1999-12-01  42.19  43.44  41.88  42.94   2115400.0
0.0
9       A  1999-12-02  43.75  45.00  43.19  44.13   2195900.0
0.0
10      A  1999-12-03  44.94  45.69  44.31  44.50   2175700.0
0.0
11      A  1999-12-06  45.25  46.44  45.19  45.75   1610000.0
0.0
12      A  1999-12-07  45.75  46.00  44.31  45.25   1585100.0
0.0
13      A  1999-12-08  45.25  45.63  44.81  45.19   1350400.0
0.0
```

```
14      A  1999-12-09  45.25  45.94  45.25  45.81   1451400.0
0.0
15      A  1999-12-10  45.69  45.94  44.75  44.75   1190800.0
0.0
16      A  1999-12-13  45.50  46.25  44.38  45.50   2875900.0
0.0
17      A  1999-12-14  45.38  45.38  42.06  43.00   1665900.0
0.0
18      A  1999-12-15  42.00  42.31  41.00  41.69   2087100.0
0.0
19      A  1999-12-16  42.00  48.00  42.00  47.25   1848300.0
0.0

    split_ratio   adj_open   adj_high    adj_low  adj_close
adj_volume y_clas
0           1.0  31.041951  34.112034  27.289627  30.018590
44739900.0      D
1           1.0  29.295415  29.336350  27.160002  27.548879
10897100.0      B
2           1.0  28.183363  30.018590  27.330562  30.018590
4705200.0       B
3           1.0  28.995229  29.766161  27.460188  27.460188
4274400.0       B
4           1.0  27.378319  28.613174  27.289627  28.012803
3464400.0       A
5           1.0  27.889999  28.312988  27.801308  28.101494
1237100.0       A
6           1.0  27.971868  28.954295  27.671682  28.742800
2914700.0       A
7           1.0  28.654109  29.295415  27.930934  28.783735
3083000.0       A
8           1.0  28.783735  29.636535  28.572240  29.295415
2115400.0       B
9           1.0  29.848030  30.700831  29.465975  30.107281
2195900.0       B
10          1.0  30.659896  31.171577  30.230085  30.359711
2175700.0       B
11          1.0  30.871391  31.683257  30.830457  31.212511
1610000.0       C
12          1.0  31.212511  31.383072  30.230085  30.871391
1585100.0       C
13          1.0  30.871391  31.130643  30.571205  30.830457
1350400.0       B
14          1.0  30.871391  31.342137  30.871391  31.253446
1451400.0       B
15          1.0  31.171577  31.342137  30.530271  30.530271
1190800.0       B
16          1.0  31.041951  31.553632  30.277842  31.041951
2875900.0       C
17          1.0  30.960082  30.960082  28.695043  29.336350
```

```
1665900.0      B
18          1.0  28.654109  28.865603  27.971868  28.442614
2087100.0      A
19          1.0  28.654109  32.747553  28.654109  32.235872
1848300.0      C
```

```
# чтение тестовой выборки
data_test = pd.read_csv('WIKI_PRICES_test.csv', sep=",")
```

```
data_test
```

```
  ticker        date   open   high    low  close     volume  ex-
dividend  \
0      A  1999-12-17  46.38  47.12  45.44  45.94  2652400.0
0.0
1      A  1999-12-20  46.25  46.94  46.13  46.88   856100.0
0.0
2      A  1999-12-21  46.69  46.69  46.00  46.63  1616200.0
0.0
3      A  1999-12-22  46.63  47.56  46.31  47.56  1363200.0
0.0
4      A  1999-12-23  47.50  50.00  47.44  49.75  1544700.0
0.0

   split_ratio   adj_open   adj_high    adj_low  adj_close  adj_volume

0          1.0  31.642323  32.147181  31.001017  31.342137   2652400.0

1          1.0  31.553632  32.024378  31.471763  31.983443    856100.0

2          1.0  31.853818  31.853818  31.383072  31.812883   1616200.0

3          1.0  31.812883  32.447367  31.594566  32.447367   1363200.0

4          1.0  32.406433  34.112034  32.365498  33.941474   1544700.0
```

```
# визуализация выборки
fig, ax = plt.subplots(figsize=(8,8))

ax.plot(data_train['high'], data_train['low'], 'b.', \
         data_test['high'], data_test['low'], 'ro')

# деления на осях и сетка
ax.xaxis.set_major_locator(ticker.MultipleLocator(1))
ax.yaxis.set_major_locator(ticker.MultipleLocator(1))
ax.grid(which='major', color = 'k')

# подписи к осям
plt.xlabel('$high$')
plt.ylabel('$low$')
```

```
# подписи
for coords in data_train[['high','low', 'close', 'y_clas']].values:
    high, low, y_cl, cl = coords[0], coords[1], coords[2], coords[3]
    #label = '{} ({})'.format(y_cl, cl)
    #ax.text(high + 1, low, label, style='italic', fontsize=7)
    ax.text(high + 1, low, cl, style='italic', fontsize=10)
    ax.text(high, low-3, y_cl, style='italic', fontsize=10)

plt.show()
```

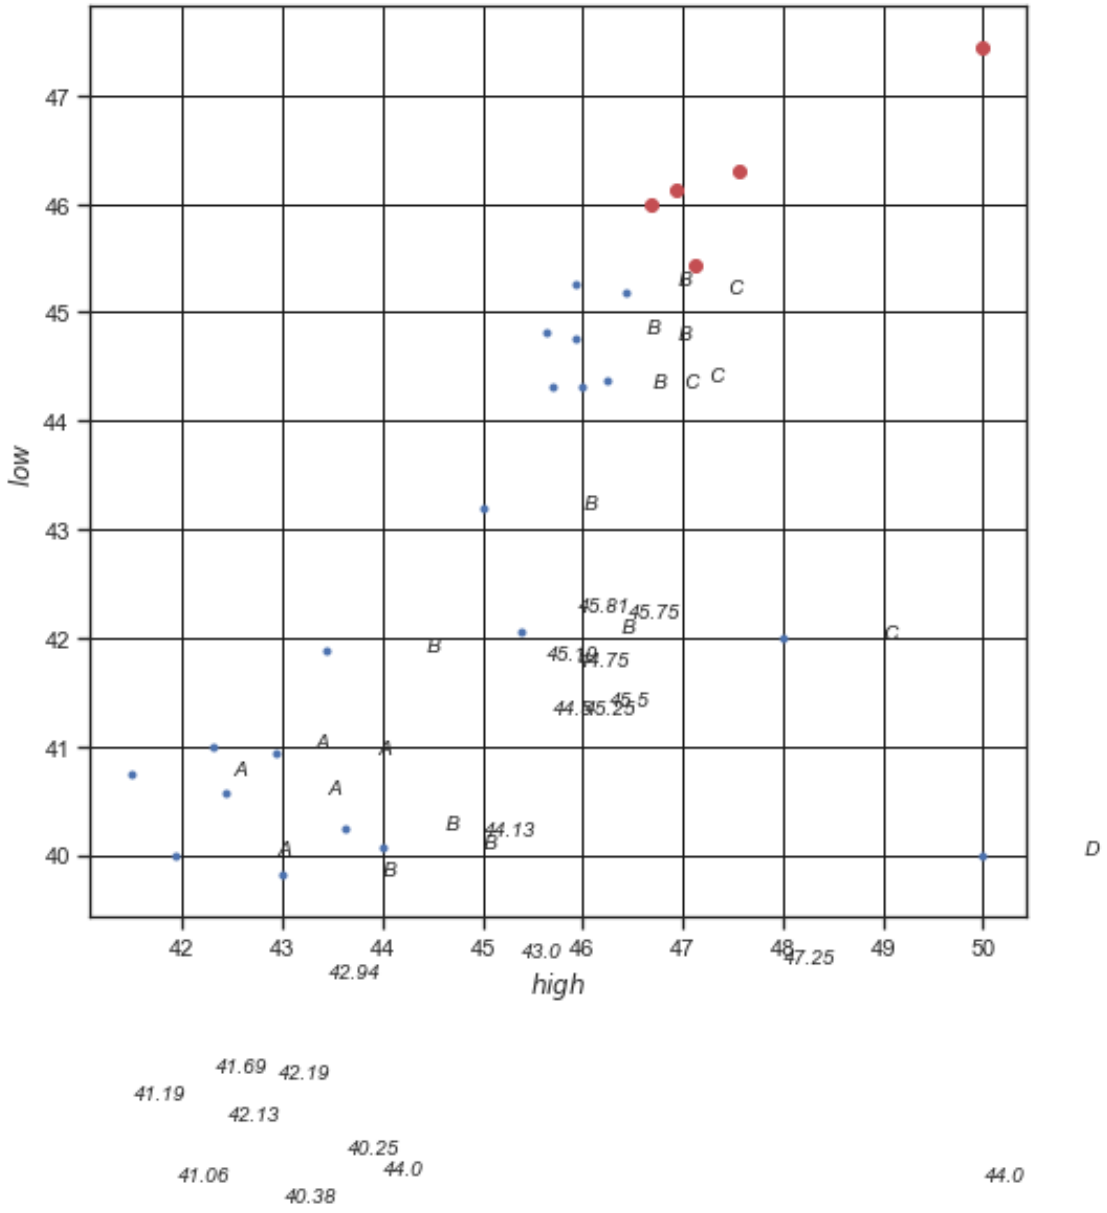


```
# создаем объект класса
simple_knn_regr = SimpleKNN()
```

```
# вызываем метод обучения
simple_knn_regr.fit(data_train[['high','low']], data_train['close'])

# параметры метода
# матрица объект-признак
simple_knn_regr._X_train
```

```
     high    low
0   50.00  40.00
1   43.00  39.81
2   44.00  40.06
3   43.63  40.25
4   41.94  40.00
5   41.50  40.75
6   42.44  40.56
7   42.94  40.94
8   43.44  41.88
9   45.00  43.19
10  45.69  44.31
11  46.44  45.19
12  46.00  44.31
13  45.63  44.81
14  45.94  45.25
15  45.94  44.75
16  46.25  44.38
17  45.38  42.06
18  42.31  41.00
19  48.00  42.00
```

```
# вектор целевого признака
simple_knn_regr._y_train
```

```
0     44.00
1     40.38
2     44.00
3     40.25
4     41.06
5     41.19
6     42.13
7     42.19
8     42.94
9     44.13
10    44.50
11    45.75
12    45.25
13    45.19
14    45.81
15    44.75
16    45.50
17    43.00
18    41.69
```

```
19    47.25
Name: close, dtype: float64
```

```
simple_knn_clas = SimpleKNN()
simple_knn_clas.fit(data_train[['high','low']], data_train['y_clas'])
```

```
simple_knn_clas._X_train
```

```
     high    low
0   50.00  40.00
1   43.00  39.81
2   44.00  40.06
3   43.63  40.25
4   41.94  40.00
5   41.50  40.75
6   42.44  40.56
7   42.94  40.94
8   43.44  41.88
9   45.00  43.19
10  45.69  44.31
11  46.44  45.19
12  46.00  44.31
13  45.63  44.81
14  45.94  45.25
15  45.94  44.75
16  46.25  44.38
17  45.38  42.06
18  42.31  41.00
19  48.00  42.00
```

```
simple_knn_clas._y_train
```

```
0     D
1     B
2     B
3     B
4     A
5     A
6     A
7     A
8     B
9     B
10    B
11    C
12    C
13    B
14    B
15    B
16    C
17    B
18    A
```

```
19    C
Name: y_clas, dtype: object
```

```
# первая строка тестовой выборки
data_test_0 = [x for x in data_test[['high','low']].iloc[0]]
data_test_0
```

```
[47.12, 45.44]
```

```
# построим предсказание для одного объекта (регрессия)
simple_knn_regr_0 = simple_knn_regr.predict_for_single_object(K=5, \
                          prediction_type=PredictionType.REGRESSION, \
                          X_o=data_test_0)
simple_knn_regr_0
```

```
************************************
Проверяемая точка:  [47.12, 45.44]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=0.72
X1=45.94, X2=45.25, y=45.81, расстояние=1.20
X1=45.94, X2=44.75, y=44.75, расстояние=1.37
X1=46.25, X2=44.38, y=45.5, расстояние=1.37
X1=46.0, X2=44.31, y=45.25, расстояние=1.59
X1=45.63, X2=44.81, y=45.19, расстояние=1.62
X1=45.69, X2=44.31, y=44.5, расстояние=1.82
X1=45.0, X2=43.19, y=44.13, расстояние=3.09
X1=48.0, X2=42.0, y=47.25, расстояние=3.55
X1=45.38, X2=42.06, y=43.0, расстояние=3.80
X1=43.44, X2=41.88, y=42.94, расстояние=5.12
X1=42.94, X2=40.94, y=42.19, расстояние=6.14
X1=50.0, X2=40.0, y=44.0, расстояние=6.16
X1=44.0, X2=40.06, y=44.0, расстояние=6.22
X1=43.63, X2=40.25, y=40.25, расстояние=6.25
X1=42.31, X2=41.0, y=41.69, расстояние=6.55
X1=42.44, X2=40.56, y=42.13, расстояние=6.76
X1=43.0, X2=39.81, y=40.38, расстояние=6.98
X1=41.5, X2=40.75, y=41.19, расстояние=7.32
X1=41.94, X2=40.0, y=41.06, расстояние=7.51

Вывод расстояния для отсортированного списка соседей:
```

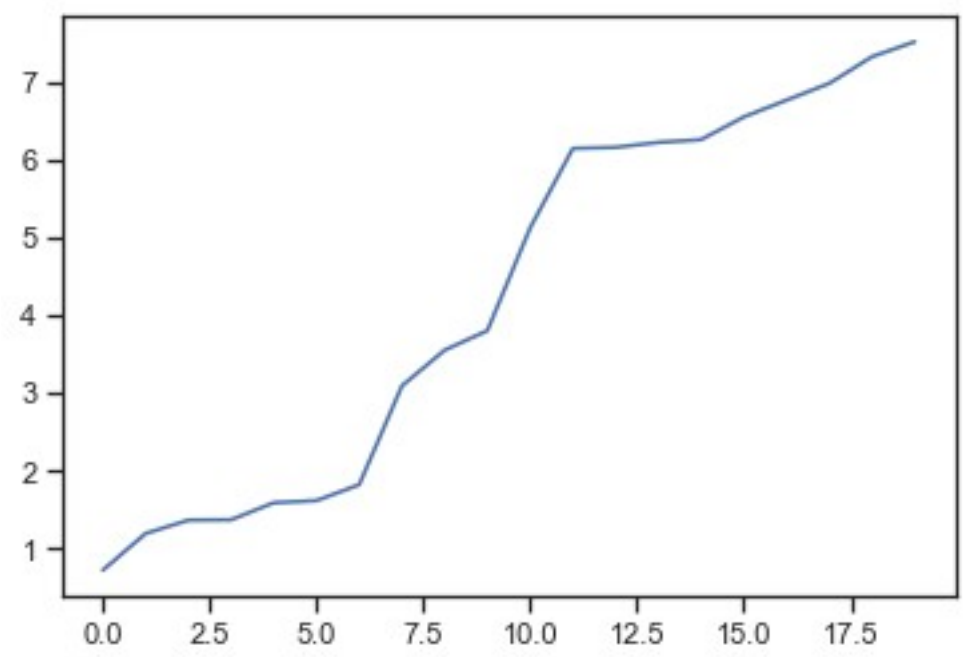


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=0.72
X1=45.94, X2=45.25, y=45.81, расстояние=1.20
X1=45.94, X2=44.75, y=44.75, расстояние=1.37
X1=46.25, X2=44.38, y=45.5, расстояние=1.37
X1=46.0, X2=44.31, y=45.25, расстояние=1.59

Визуализация K ближайших соседей:
```

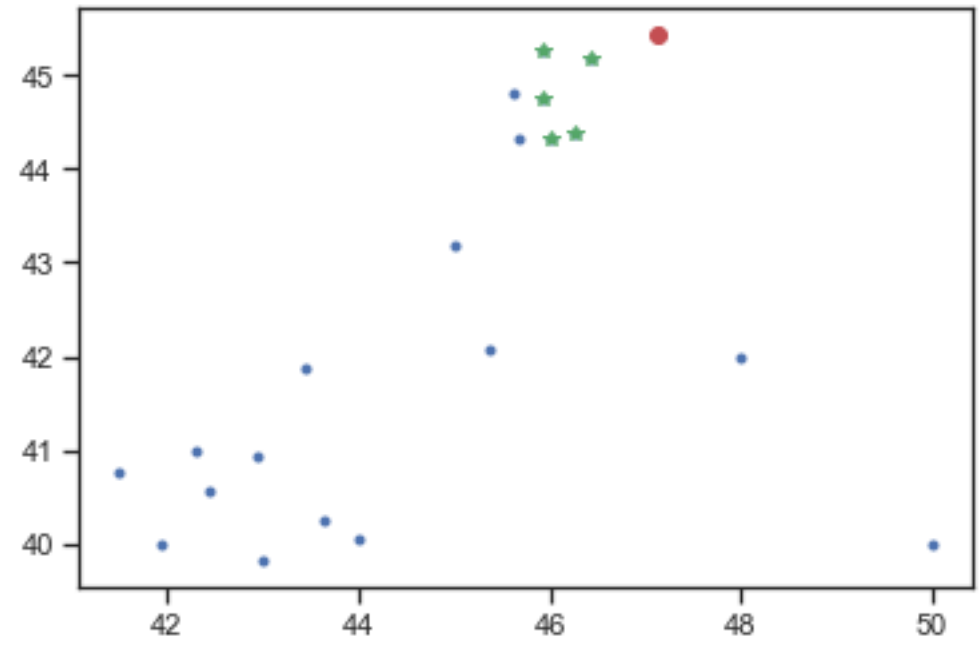


```
45.412
```

```
# Среднее значение y для соседей
np.mean([45.75, 45.81, 44.75, 45.5, 45.25])
```

```
45.412
```

```
# построим предсказание для одного объекта (классификация)
simple_knn_clas_0 = simple_knn_clas.predict_for_single_object(K=5, \

prediction_type=PredictionType.CLASSIFICATION, \
                            X_o=data_test_0)
simple_knn_clas_0
```

```
************************************
Проверяемая точка:  [47.12, 45.44]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=C, расстояние=0.72
X1=45.94, X2=45.25, y=B, расстояние=1.20
X1=45.94, X2=44.75, y=B, расстояние=1.37
X1=46.25, X2=44.38, y=C, расстояние=1.37
X1=46.0, X2=44.31, y=C, расстояние=1.59
X1=45.63, X2=44.81, y=B, расстояние=1.62
X1=45.69, X2=44.31, y=B, расстояние=1.82
X1=45.0, X2=43.19, y=B, расстояние=3.09
X1=48.0, X2=42.0, y=C, расстояние=3.55
X1=45.38, X2=42.06, y=B, расстояние=3.80
X1=43.44, X2=41.88, y=B, расстояние=5.12
X1=42.94, X2=40.94, y=A, расстояние=6.14
X1=50.0, X2=40.0, y=D, расстояние=6.16
X1=44.0, X2=40.06, y=B, расстояние=6.22
X1=43.63, X2=40.25, y=B, расстояние=6.25
X1=42.31, X2=41.0, y=A, расстояние=6.55
X1=42.44, X2=40.56, y=A, расстояние=6.76
X1=43.0, X2=39.81, y=B, расстояние=6.98
X1=41.5, X2=40.75, y=A, расстояние=7.32
X1=41.94, X2=40.0, y=A, расстояние=7.51

Вывод расстояния для отсортированного списка соседей:
```

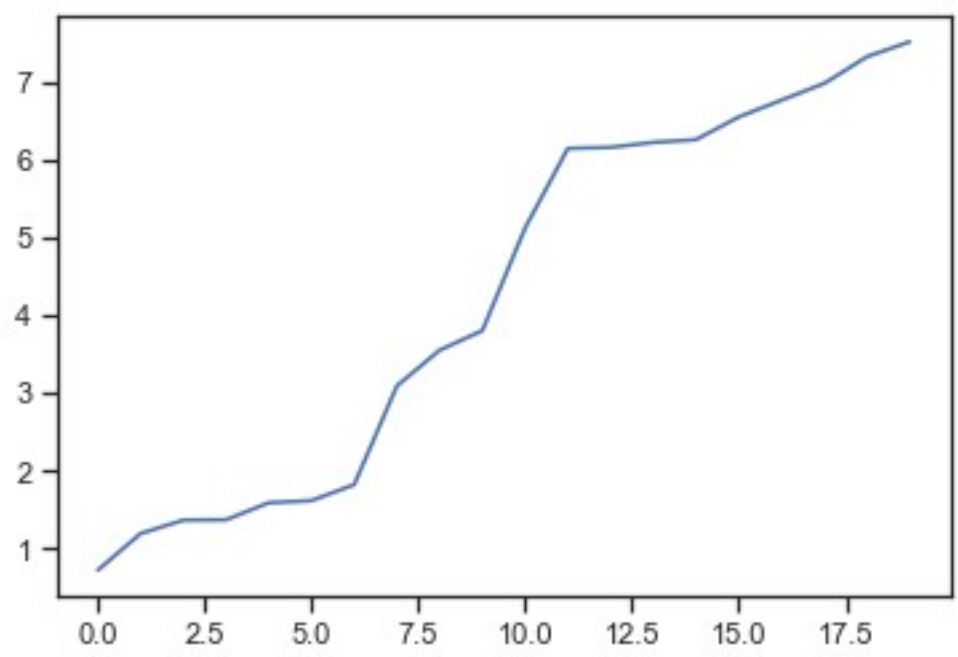


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=C, расстояние=0.72
X1=45.94, X2=45.25, y=B, расстояние=1.20
X1=45.94, X2=44.75, y=B, расстояние=1.37
X1=46.25, X2=44.38, y=C, расстояние=1.37
X1=46.0, X2=44.31, y=C, расстояние=1.59
```

Визуализация K ближайших соседей:

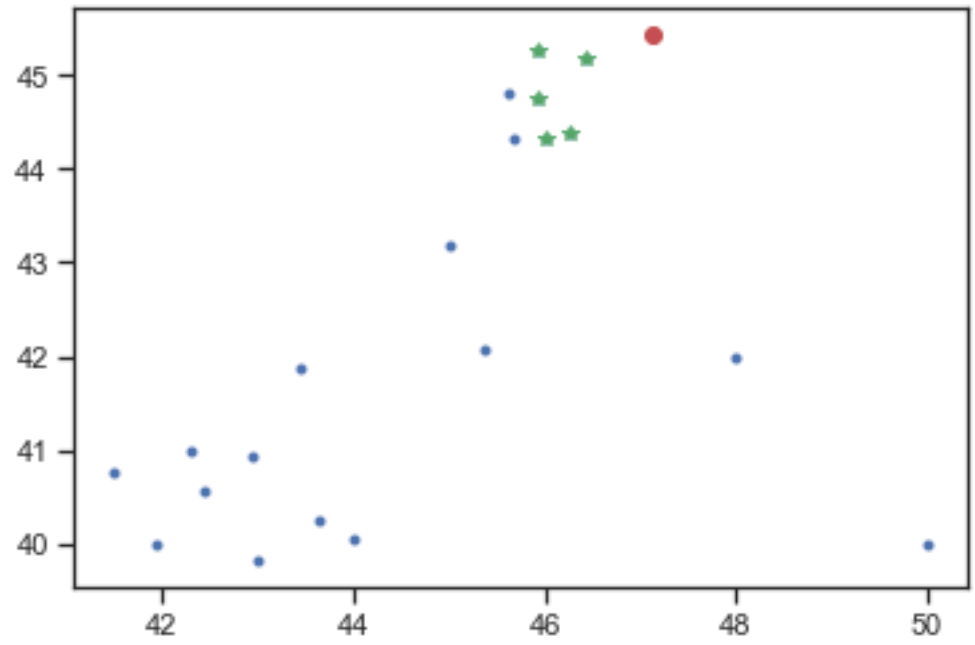

```
Классы, соответствующие K ближайшим соседям:
класс=C, количество элементов=3
класс=B, количество элементов=2

'C'
```

```
# Для всех объектов тестовой выборки (регрессия)
simple_knn_regr_prediction = simple_knn_regr.predict(K=5, \
                           prediction_type=PredictionType.REGRESSION, \
                           X_test=data_test[['high','low']])
simple_knn_regr_prediction
```

```
************************************
Проверяемая точка:  [47.12, 45.44]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=0.72
X1=45.94, X2=45.25, y=45.81, расстояние=1.20
X1=45.94, X2=44.75, y=44.75, расстояние=1.37
X1=46.25, X2=44.38, y=45.5, расстояние=1.37
X1=46.0, X2=44.31, y=45.25, расстояние=1.59
X1=45.63, X2=44.81, y=45.19, расстояние=1.62
X1=45.69, X2=44.31, y=44.5, расстояние=1.82
X1=45.0, X2=43.19, y=44.13, расстояние=3.09
X1=48.0, X2=42.0, y=47.25, расстояние=3.55
X1=45.38, X2=42.06, y=43.0, расстояние=3.80
X1=43.44, X2=41.88, y=42.94, расстояние=5.12
X1=42.94, X2=40.94, y=42.19, расстояние=6.14
X1=50.0, X2=40.0, y=44.0, расстояние=6.16
X1=44.0, X2=40.06, y=44.0, расстояние=6.22
X1=43.63, X2=40.25, y=40.25, расстояние=6.25
X1=42.31, X2=41.0, y=41.69, расстояние=6.55
X1=42.44, X2=40.56, y=42.13, расстояние=6.76
X1=43.0, X2=39.81, y=40.38, расстояние=6.98
X1=41.5, X2=40.75, y=41.19, расстояние=7.32
X1=41.94, X2=40.0, y=41.06, расстояние=7.51

Вывод расстояния для отсортированного списка соседей:
```

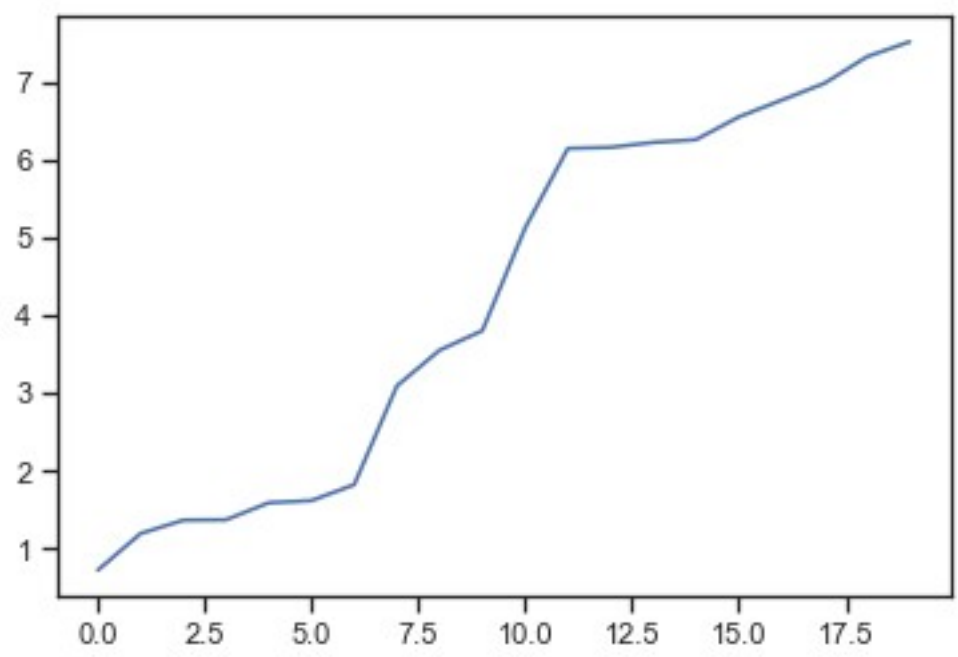


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=0.72
X1=45.94, X2=45.25, y=45.81, расстояние=1.20
X1=45.94, X2=44.75, y=44.75, расстояние=1.37
X1=46.25, X2=44.38, y=45.5, расстояние=1.37
X1=46.0, X2=44.31, y=45.25, расстояние=1.59
```

Визуализация K ближайших соседей:

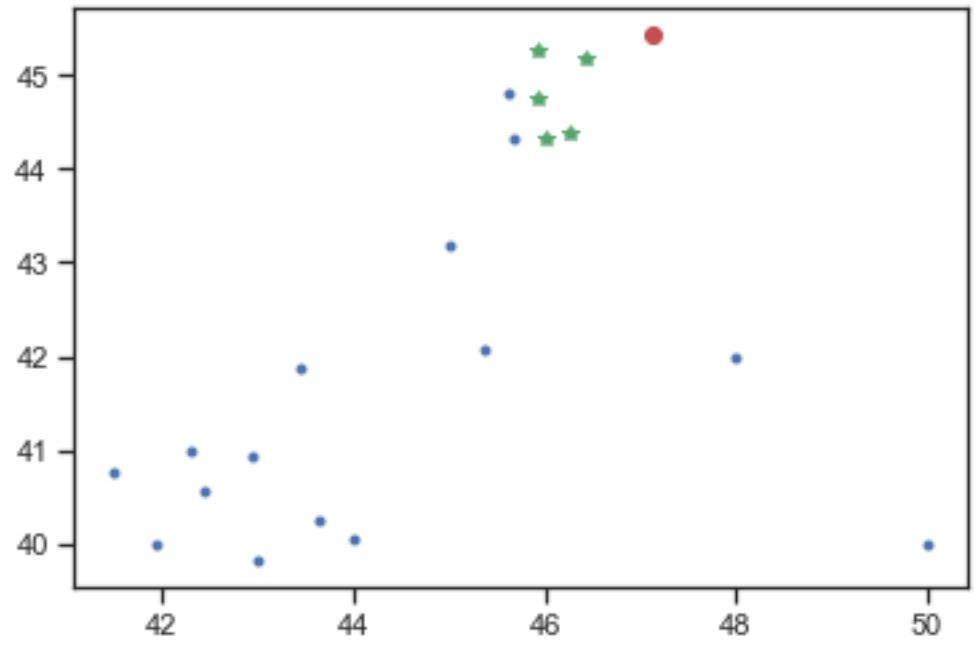

```
************************************
Проверяемая точка:  [46.94, 46.13]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=1.06
X1=45.94, X2=45.25, y=45.81, расстояние=1.33
X1=45.94, X2=44.75, y=44.75, расстояние=1.70
X1=45.63, X2=44.81, y=45.19, расстояние=1.86
X1=46.25, X2=44.38, y=45.5, расстояние=1.88
X1=46.0, X2=44.31, y=45.25, расстояние=2.05
X1=45.69, X2=44.31, y=44.5, расстояние=2.21
X1=45.0, X2=43.19, y=44.13, расстояние=3.52
X1=48.0, X2=42.0, y=47.25, расстояние=4.26
X1=45.38, X2=42.06, y=43.0, расстояние=4.36
X1=43.44, X2=41.88, y=42.94, расстояние=5.51
X1=42.94, X2=40.94, y=42.19, расстояние=6.55
X1=44.0, X2=40.06, y=44.0, расстояние=6.74
X1=43.63, X2=40.25, y=40.25, расстояние=6.75
X1=50.0, X2=40.0, y=44.0, расстояние=6.85
X1=42.31, X2=41.0, y=41.69, расстояние=6.91
X1=42.44, X2=40.56, y=42.13, расстояние=7.16
X1=43.0, X2=39.81, y=40.38, расстояние=7.45
X1=41.5, X2=40.75, y=41.19, расстояние=7.65
X1=41.94, X2=40.0, y=41.06, расстояние=7.91

Вывод расстояния для отсортированного списка соседей:
```

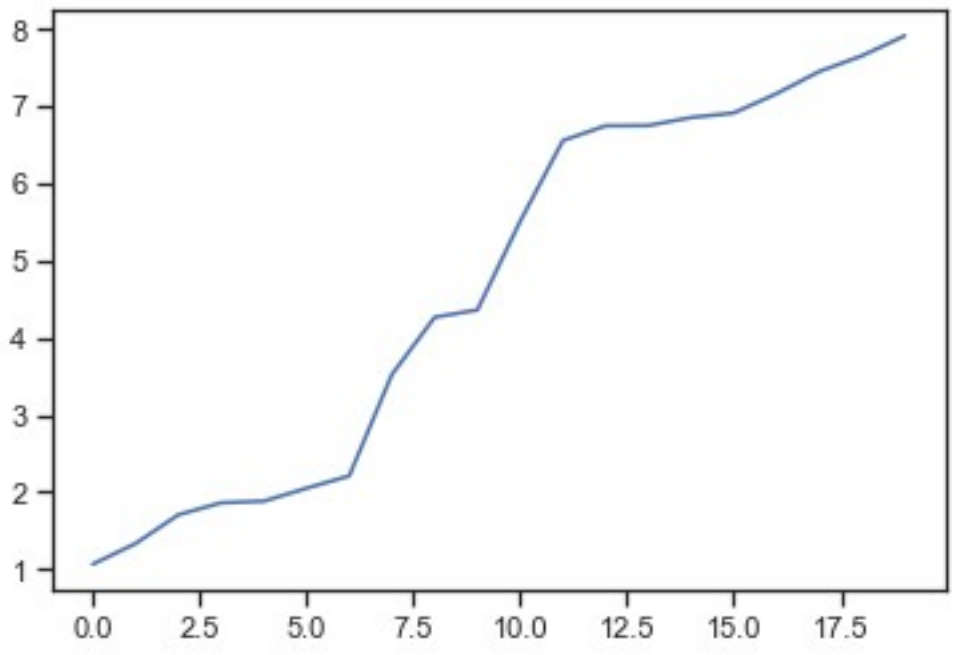


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=1.06
```

```
X1=45.94, X2=45.25, y=45.81, расстояние=1.33
X1=45.94, X2=44.75, y=44.75, расстояние=1.70
X1=45.63, X2=44.81, y=45.19, расстояние=1.86
X1=46.25, X2=44.38, y=45.5, расстояние=1.88

Визуализация K ближайших соседей:
```

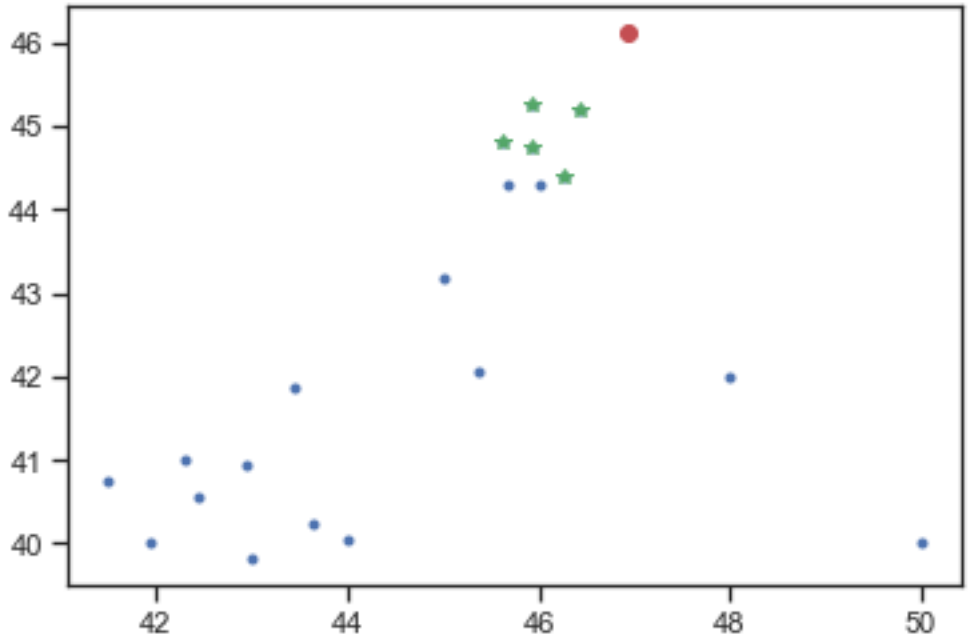


```
**************************************
Проверяемая точка:  [46.69, 46.0]
**************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=0.85
X1=45.94, X2=45.25, y=45.81, расстояние=1.06
X1=45.94, X2=44.75, y=44.75, расстояние=1.46
X1=45.63, X2=44.81, y=45.19, расстояние=1.59
X1=46.25, X2=44.38, y=45.5, расстояние=1.68
X1=46.0, X2=44.31, y=45.25, расстояние=1.83
X1=45.69, X2=44.31, y=44.5, расстояние=1.96
X1=45.0, X2=43.19, y=44.13, расстояние=3.28
X1=45.38, X2=42.06, y=43.0, расстояние=4.15
X1=48.0, X2=42.0, y=47.25, расстояние=4.21
X1=43.44, X2=41.88, y=42.94, расстояние=5.25
X1=42.94, X2=40.94, y=42.19, расстояние=6.30
X1=43.63, X2=40.25, y=40.25, расстояние=6.51
X1=44.0, X2=40.06, y=44.0, расстояние=6.52
X1=42.31, X2=41.0, y=41.69, расстояние=6.65
X1=50.0, X2=40.0, y=44.0, расстояние=6.85
X1=42.44, X2=40.56, y=42.13, расстояние=6.90
X1=43.0, X2=39.81, y=40.38, расстояние=7.21
```

X1=41.5, X2=40.75, y=41.19, расстояние=7.38
X1=41.94, X2=40.0, y=41.06, расстояние=7.65

Вывод расстояния для отсортированного списка соседей:

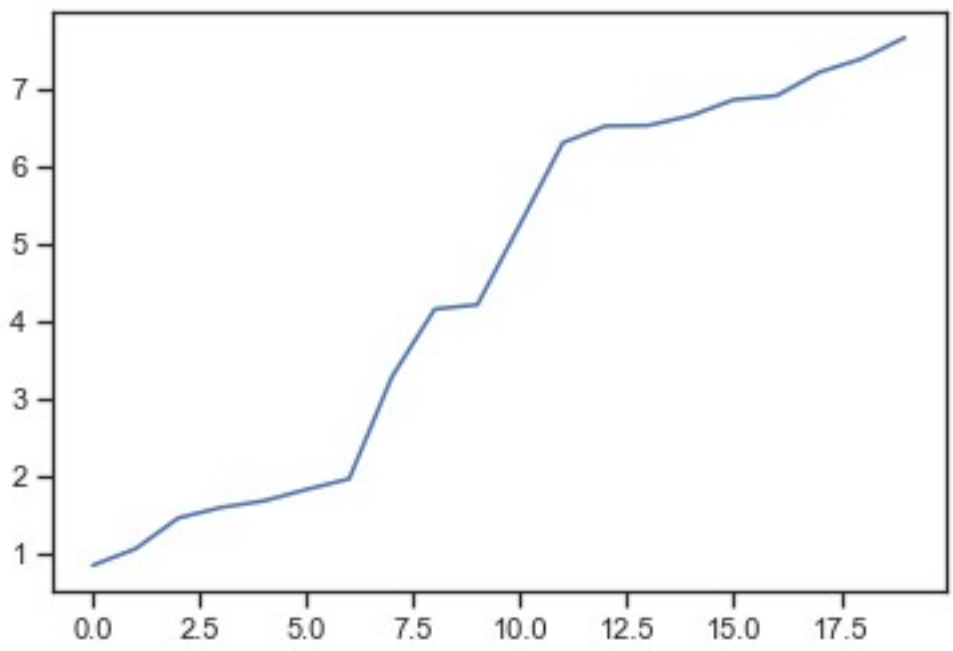

Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=0.85
X1=45.94, X2=45.25, y=45.81, расстояние=1.06
X1=45.94, X2=44.75, y=44.75, расстояние=1.46
X1=45.63, X2=44.81, y=45.19, расстояние=1.59
X1=46.25, X2=44.38, y=45.5, расстояние=1.68

Визуализация K ближайших соседей:

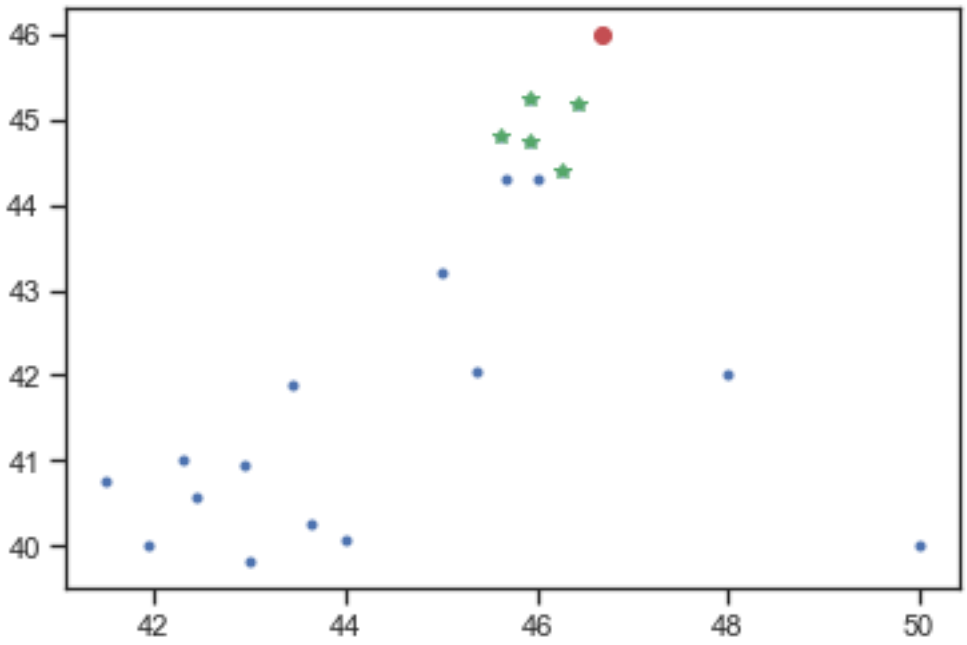


```
************************************
Проверяемая точка:  [47.56, 46.31]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=1.58
X1=45.94, X2=45.25, y=45.81, расстояние=1.94
X1=45.94, X2=44.75, y=44.75, расстояние=2.25
X1=46.25, X2=44.38, y=45.5, расстояние=2.33
X1=45.63, X2=44.81, y=45.19, расстояние=2.44
X1=46.0, X2=44.31, y=45.25, расстояние=2.54
X1=45.69, X2=44.31, y=44.5, расстояние=2.74
X1=45.0, X2=43.19, y=44.13, расстояние=4.04
X1=48.0, X2=42.0, y=47.25, расстояние=4.33
X1=45.38, X2=42.06, y=43.0, расстояние=4.78
X1=43.44, X2=41.88, y=42.94, расстояние=6.05
X1=50.0, X2=40.0, y=44.0, расстояние=6.77
X1=42.94, X2=40.94, y=42.19, расстояние=7.08
X1=44.0, X2=40.06, y=44.0, расстояние=7.19
X1=43.63, X2=40.25, y=40.25, расстояние=7.22
X1=42.31, X2=41.0, y=41.69, расстояние=7.47
X1=42.44, X2=40.56, y=42.13, расстояние=7.70
X1=43.0, X2=39.81, y=40.38, расстояние=7.94
X1=41.5, X2=40.75, y=41.19, расстояние=8.22
X1=41.94, X2=40.0, y=41.06, расстояние=8.45

Вывод расстояния для отсортированного списка соседей:
```

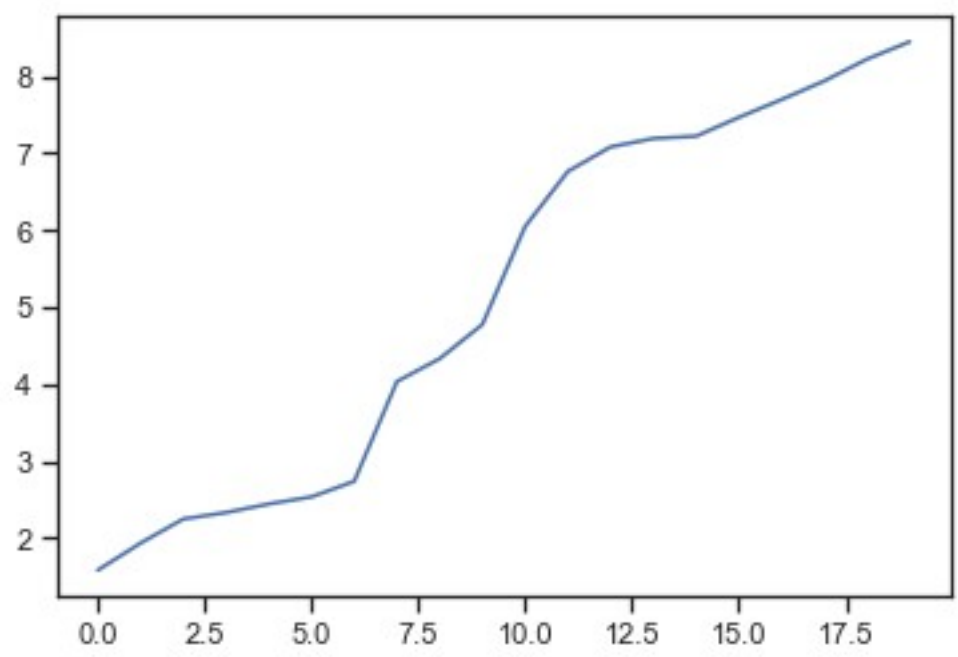


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=1.58
X1=45.94, X2=45.25, y=45.81, расстояние=1.94
X1=45.94, X2=44.75, y=44.75, расстояние=2.25
X1=46.25, X2=44.38, y=45.5, расстояние=2.33
X1=45.63, X2=44.81, y=45.19, расстояние=2.44
```

Визуализация K ближайших соседей:

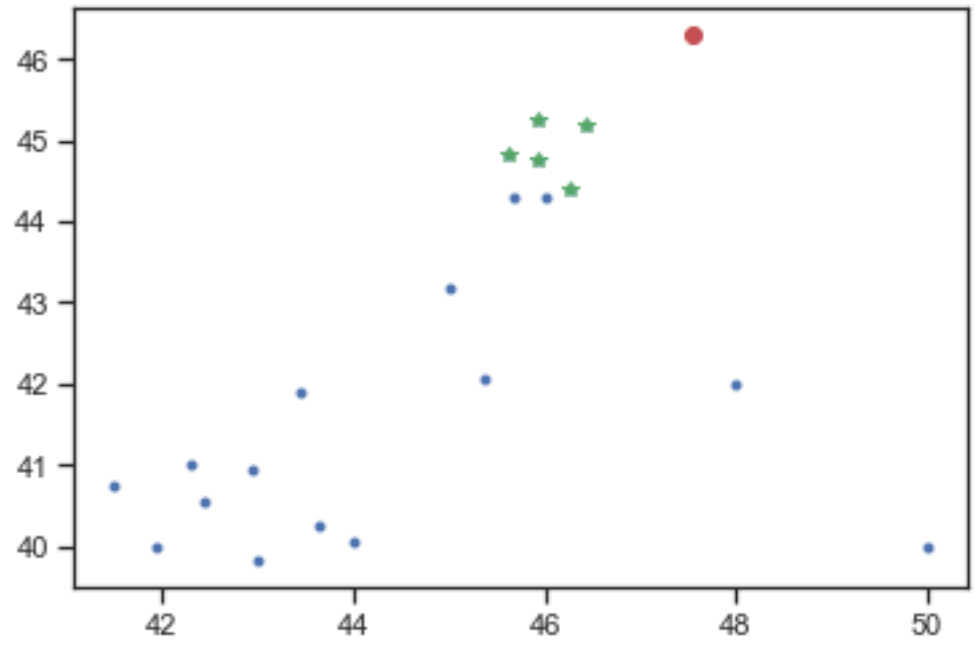

```
************************************
Проверяемая точка:  [50.0, 47.44]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=4.21
X1=45.94, X2=45.25, y=45.81, расстояние=4.61
X1=46.25, X2=44.38, y=45.5, расстояние=4.84
X1=45.94, X2=44.75, y=44.75, расстояние=4.87
X1=46.0, X2=44.31, y=45.25, расстояние=5.08
X1=45.63, X2=44.81, y=45.19, расстояние=5.10
X1=45.69, X2=44.31, y=44.5, расстояние=5.33
X1=48.0, X2=42.0, y=47.25, расстояние=5.80
X1=45.0, X2=43.19, y=44.13, расстояние=6.56
X1=45.38, X2=42.06, y=43.0, расстояние=7.09
X1=50.0, X2=40.0, y=44.0, расстояние=7.44
X1=43.44, X2=41.88, y=42.94, расстояние=8.60
X1=44.0, X2=40.06, y=44.0, расстояние=9.51
X1=42.94, X2=40.94, y=42.19, расстояние=9.60
X1=43.63, X2=40.25, y=40.25, расстояние=9.61
X1=42.31, X2=41.0, y=41.69, расстояние=10.03
X1=42.44, X2=40.56, y=42.13, расстояние=10.22
X1=43.0, X2=39.81, y=40.38, расстояние=10.35
X1=41.5, X2=40.75, y=41.19, расстояние=10.82
X1=41.94, X2=40.0, y=41.06, расстояние=10.97

Вывод расстояния для отсортированного списка соседей:
```

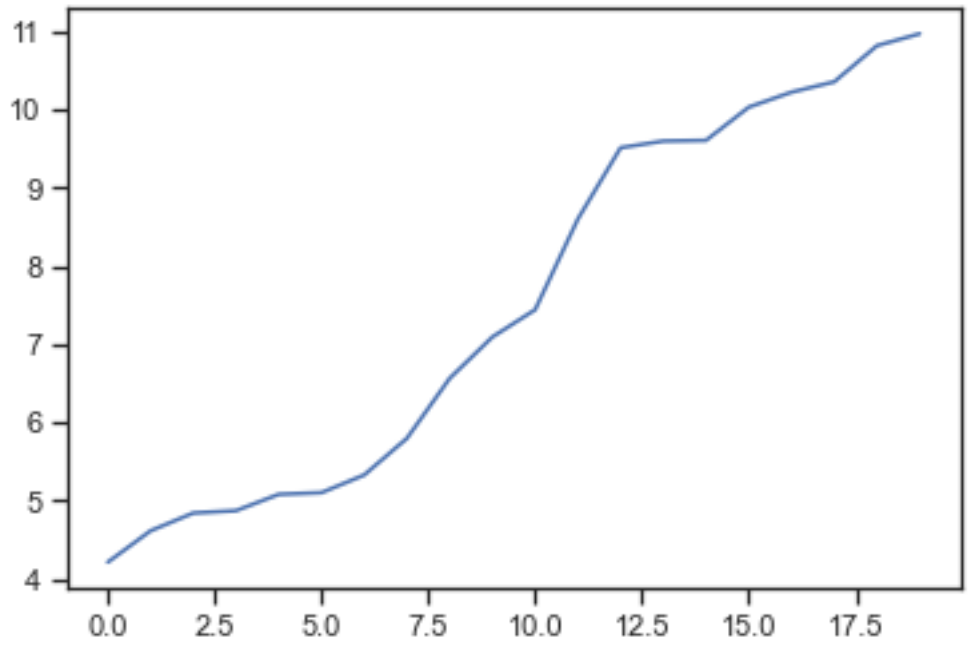


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=45.75, расстояние=4.21
```

```
X1=45.94, X2=45.25, y=45.81, расстояние=4.61
X1=46.25, X2=44.38, y=45.5, расстояние=4.84
X1=45.94, X2=44.75, y=44.75, расстояние=4.87
X1=46.0, X2=44.31, y=45.25, расстояние=5.08

Визуализация K ближайших соседей:
```

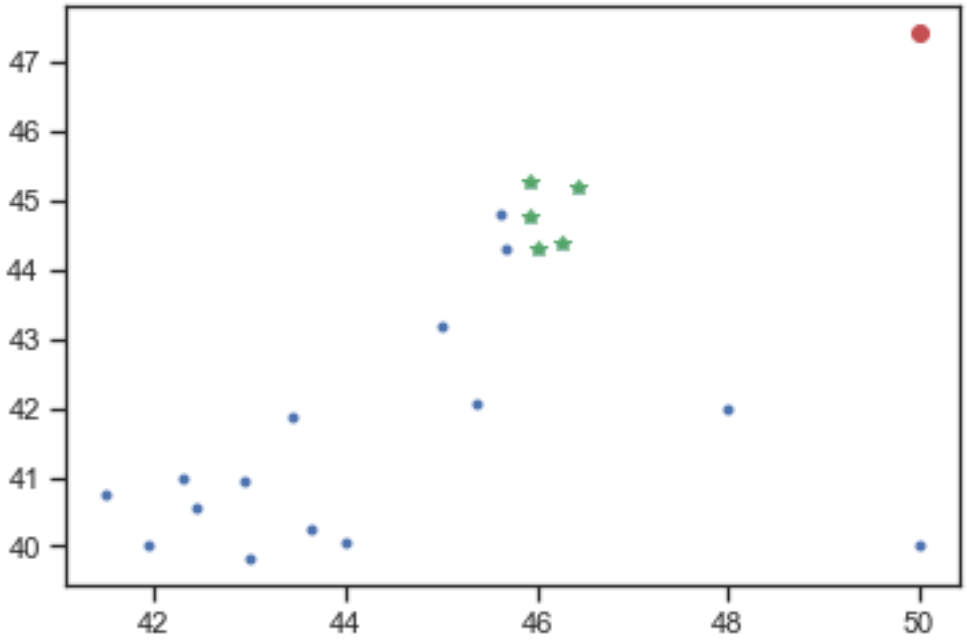


```
[45.412, 45.4, 45.4, 45.4, 45.412]
```

```
# Для всех объектов тестовой выборки (классификация)
simple_knn_clas_prediction = simple_knn_clas.predict(K=3, \

prediction_type=PredictionType.CLASSIFICATION, \
                            X_test=data_test[['high','low']])
simple_knn_clas_prediction


**************************************
Проверяемая точка:  [47.12, 45.44]
**************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=C, расстояние=0.72
X1=45.94, X2=45.25, y=B, расстояние=1.20
X1=45.94, X2=44.75, y=B, расстояние=1.37
X1=46.25, X2=44.38, y=C, расстояние=1.37
X1=46.0, X2=44.31, y=C, расстояние=1.59
X1=45.63, X2=44.81, y=B, расстояние=1.62
X1=45.69, X2=44.31, y=B, расстояние=1.82
X1=45.0, X2=43.19, y=B, расстояние=3.09
X1=48.0, X2=42.0, y=C, расстояние=3.55
```

```
X1=45.38, X2=42.06, y=B, расстояние=3.80
X1=43.44, X2=41.88, y=B, расстояние=5.12
X1=42.94, X2=40.94, y=A, расстояние=6.14
X1=50.0, X2=40.0, y=D, расстояние=6.16
X1=44.0, X2=40.06, y=B, расстояние=6.22
X1=43.63, X2=40.25, y=B, расстояние=6.25
X1=42.31, X2=41.0, y=A, расстояние=6.55
X1=42.44, X2=40.56, y=A, расстояние=6.76
X1=43.0, X2=39.81, y=B, расстояние=6.98
X1=41.5, X2=40.75, y=A, расстояние=7.32
X1=41.94, X2=40.0, y=A, расстояние=7.51

Вывод расстояния для отсортированного списка соседей:
```

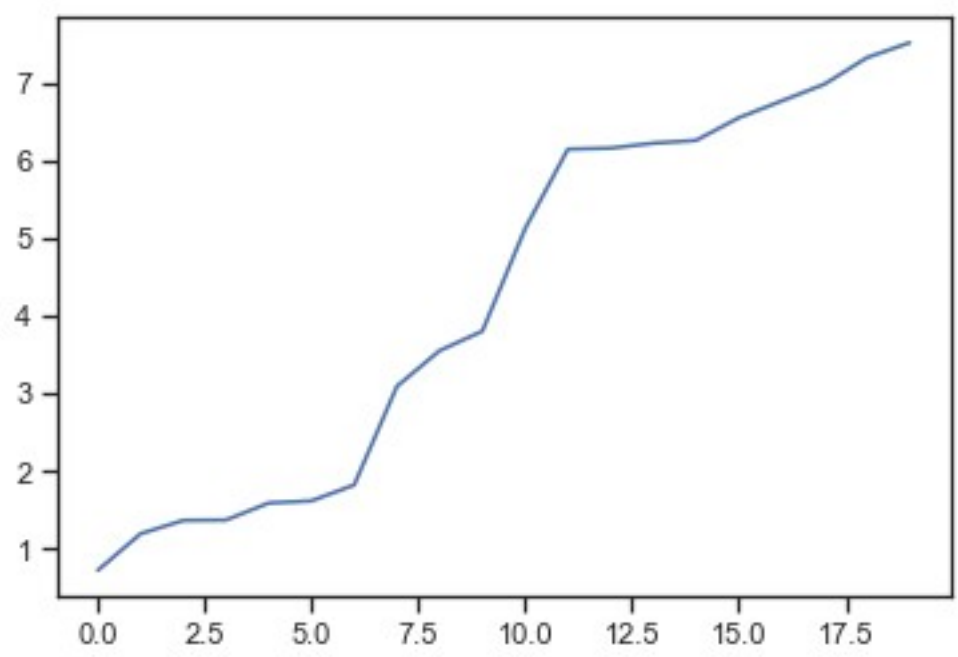


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=C, расстояние=0.72
X1=45.94, X2=45.25, y=B, расстояние=1.20
X1=45.94, X2=44.75, y=B, расстояние=1.37

Визуализация K ближайших соседей:
```

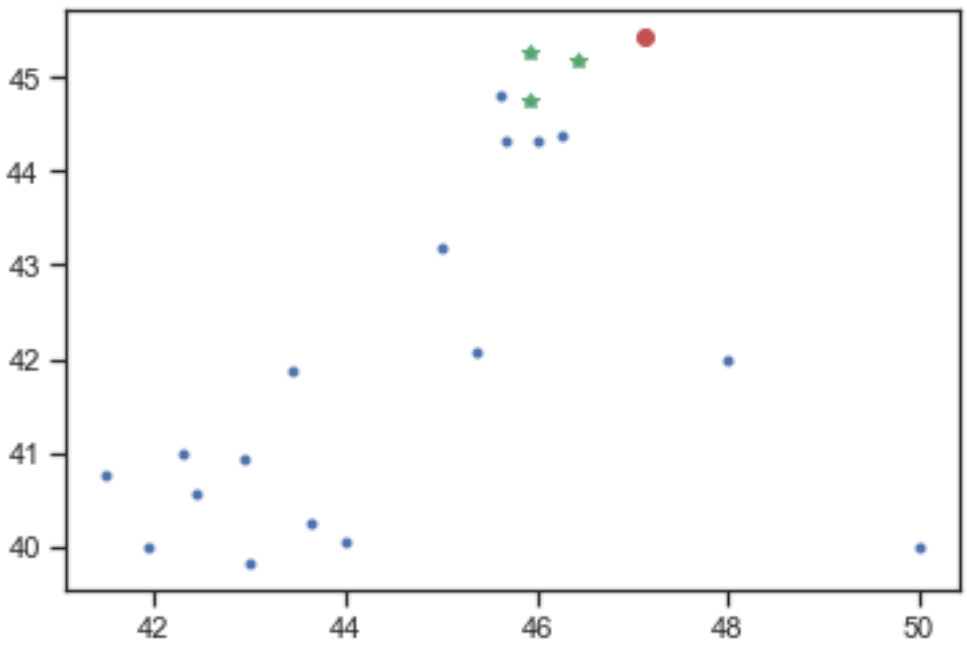


```
Классы, соответствующие K ближайшим соседям:
класс=B, количество элементов=2
класс=C, количество элементов=1

************************************
Проверяемая точка:  [46.94, 46.13]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=C, расстояние=1.06
X1=45.94, X2=45.25, y=B, расстояние=1.33
X1=45.94, X2=44.75, y=B, расстояние=1.70
X1=45.63, X2=44.81, y=B, расстояние=1.86
X1=46.25, X2=44.38, y=C, расстояние=1.88
X1=46.0, X2=44.31, y=C, расстояние=2.05
X1=45.69, X2=44.31, y=B, расстояние=2.21
X1=45.0, X2=43.19, y=B, расстояние=3.52
X1=48.0, X2=42.0, y=C, расстояние=4.26
X1=45.38, X2=42.06, y=B, расстояние=4.36
X1=43.44, X2=41.88, y=B, расстояние=5.51
X1=42.94, X2=40.94, y=A, расстояние=6.55
X1=44.0, X2=40.06, y=B, расстояние=6.74
X1=43.63, X2=40.25, y=B, расстояние=6.75
X1=50.0, X2=40.0, y=D, расстояние=6.85
X1=42.31, X2=41.0, y=A, расстояние=6.91
X1=42.44, X2=40.56, y=A, расстояние=7.16
X1=43.0, X2=39.81, y=B, расстояние=7.45
X1=41.5, X2=40.75, y=A, расстояние=7.65
X1=41.94, X2=40.0, y=A, расстояние=7.91

Вывод расстояния для отсортированного списка соседей:
```

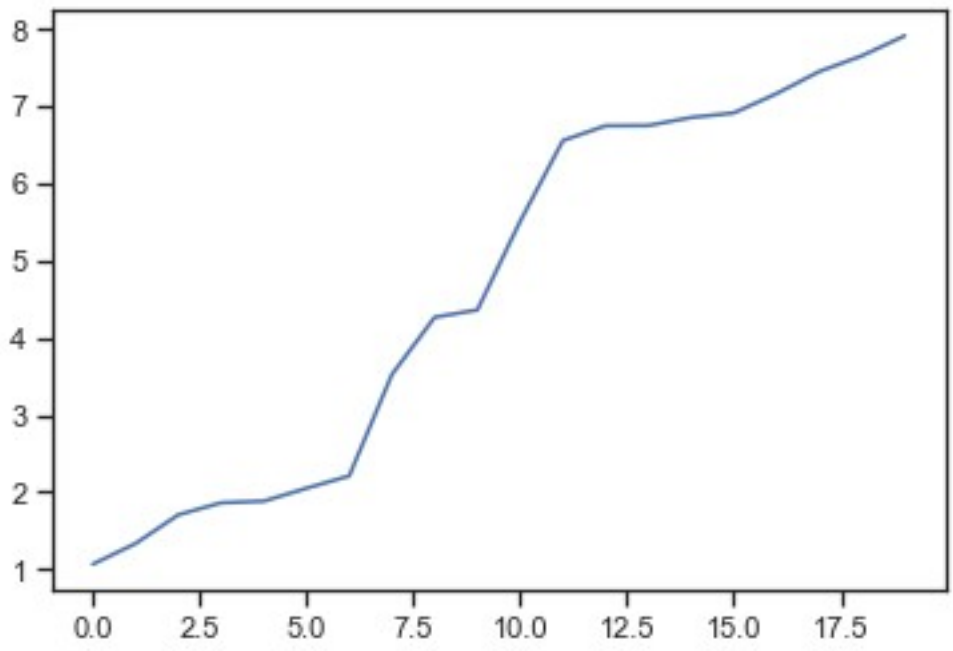


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=C, расстояние=1.06
X1=45.94, X2=45.25, y=B, расстояние=1.33
X1=45.94, X2=44.75, y=B, расстояние=1.70
```

Визуализация K ближайших соседей:

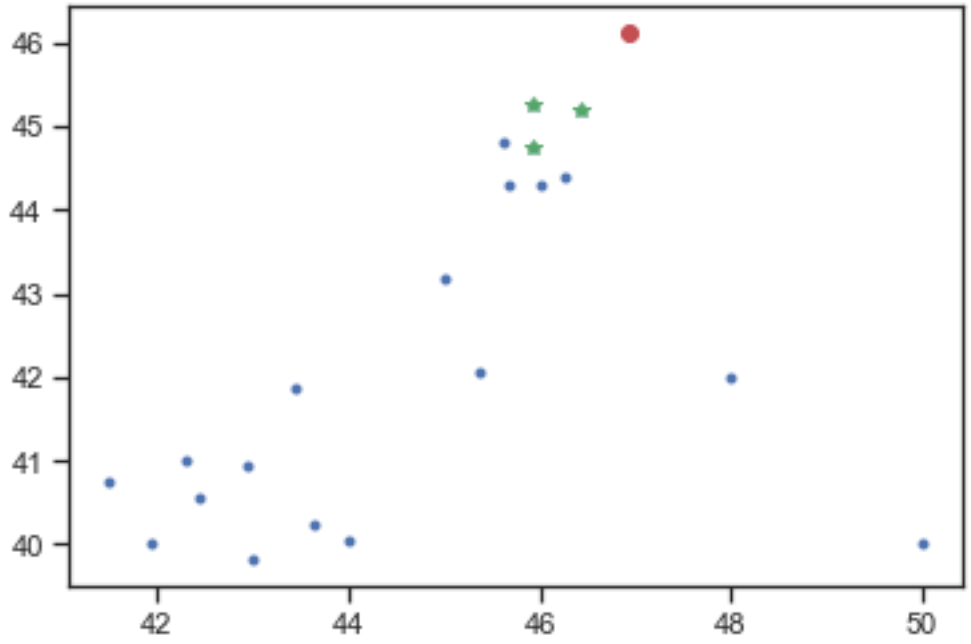


```
Классы, соответствующие K ближайшим соседям:
класс=B, количество элементов=2
класс=C, количество элементов=1
```

```
************************************
Проверяемая точка:  [46.69, 46.0]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=C, расстояние=0.85
X1=45.94, X2=45.25, y=B, расстояние=1.06
X1=45.94, X2=44.75, y=B, расстояние=1.46
X1=45.63, X2=44.81, y=B, расстояние=1.59
X1=46.25, X2=44.38, y=C, расстояние=1.68
X1=46.0, X2=44.31, y=C, расстояние=1.83
X1=45.69, X2=44.31, y=B, расстояние=1.96
X1=45.0, X2=43.19, y=B, расстояние=3.28
X1=45.38, X2=42.06, y=B, расстояние=4.15
X1=48.0, X2=42.0, y=C, расстояние=4.21
X1=43.44, X2=41.88, y=B, расстояние=5.25
X1=42.94, X2=40.94, y=A, расстояние=6.30
X1=43.63, X2=40.25, y=B, расстояние=6.51
X1=44.0, X2=40.06, y=B, расстояние=6.52
X1=42.31, X2=41.0, y=A, расстояние=6.65
X1=50.0, X2=40.0, y=D, расстояние=6.85
X1=42.44, X2=40.56, y=A, расстояние=6.90
X1=43.0, X2=39.81, y=B, расстояние=7.21
X1=41.5, X2=40.75, y=A, расстояние=7.38
X1=41.94, X2=40.0, y=A, расстояние=7.65

Вывод расстояния для отсортированного списка соседей:
```

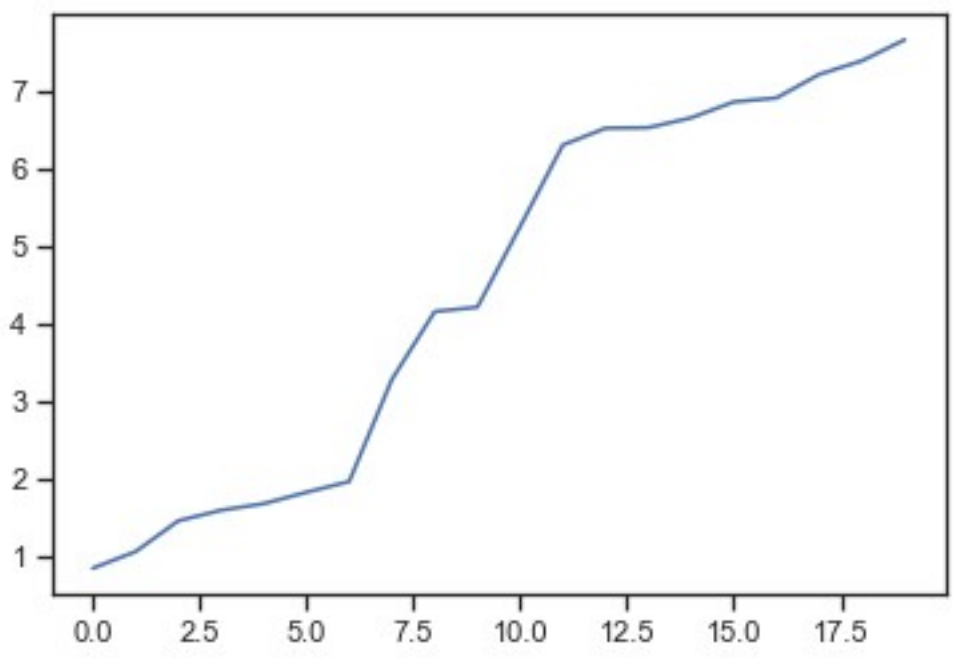


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=C, расстояние=0.85
```

```
X1=45.94, X2=45.25, y=B, расстояние=1.06
X1=45.94, X2=44.75, y=B, расстояние=1.46

Визуализация K ближайших соседей:
```

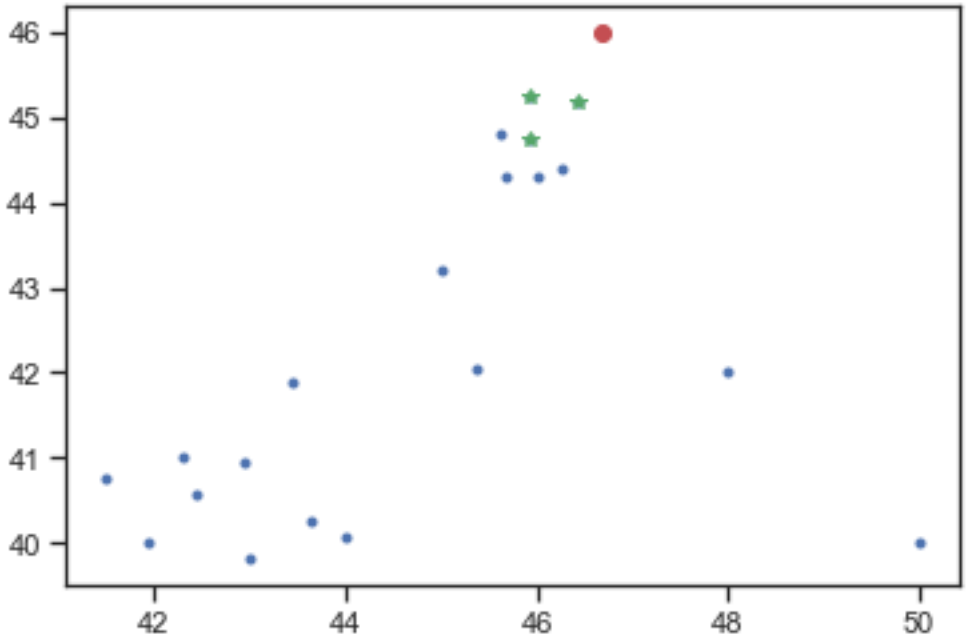


```
Классы, соответствующие K ближайшим соседям:
класс=B, количество элементов=2
класс=C, количество элементов=1

************************************
Проверяемая точка:  [47.56, 46.31]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=C, расстояние=1.58
X1=45.94, X2=45.25, y=B, расстояние=1.94
X1=45.94, X2=44.75, y=B, расстояние=2.25
X1=46.25, X2=44.38, y=C, расстояние=2.33
X1=45.63, X2=44.81, y=B, расстояние=2.44
X1=46.0, X2=44.31, y=C, расстояние=2.54
X1=45.69, X2=44.31, y=B, расстояние=2.74
X1=45.0, X2=43.19, y=B, расстояние=4.04
X1=48.0, X2=42.0, y=C, расстояние=4.33
X1=45.38, X2=42.06, y=B, расстояние=4.78
X1=43.44, X2=41.88, y=B, расстояние=6.05
X1=50.0, X2=40.0, y=D, расстояние=6.77
X1=42.94, X2=40.94, y=A, расстояние=7.08
X1=44.0, X2=40.06, y=B, расстояние=7.19
X1=43.63, X2=40.25, y=B, расстояние=7.22
X1=42.31, X2=41.0, y=A, расстояние=7.47
X1=42.44, X2=40.56, y=A, расстояние=7.70
```

```
X1=43.0, X2=39.81, y=B, расстояние=7.94
X1=41.5, X2=40.75, y=A, расстояние=8.22
X1=41.94, X2=40.0, y=A, расстояние=8.45

Вывод расстояния для отсортированного списка соседей:
```

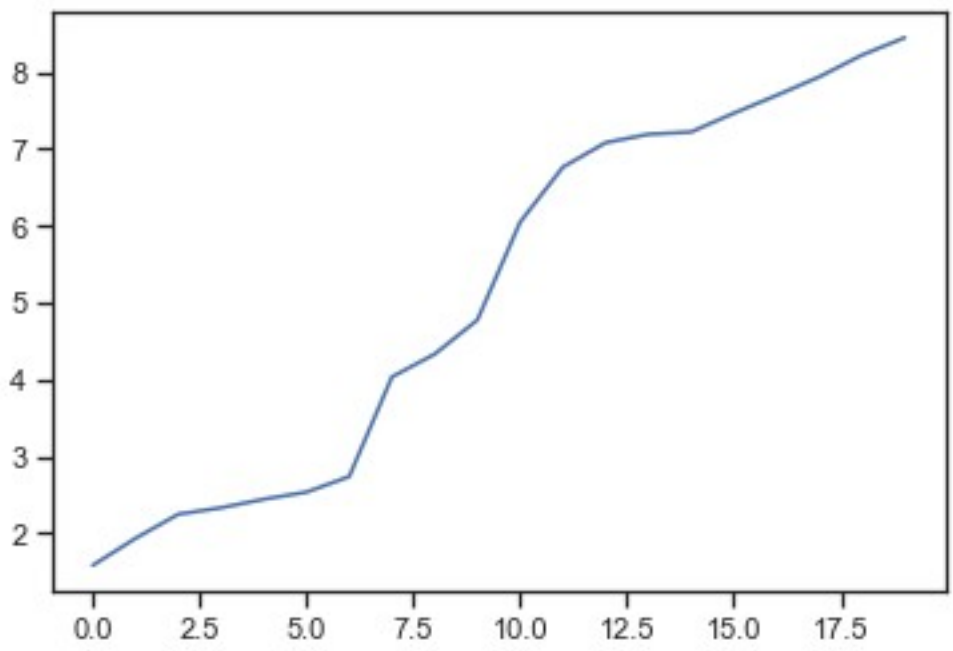


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=C, расстояние=1.58
X1=45.94, X2=45.25, y=B, расстояние=1.94
X1=45.94, X2=44.75, y=B, расстояние=2.25

Визуализация K ближайших соседей:
```

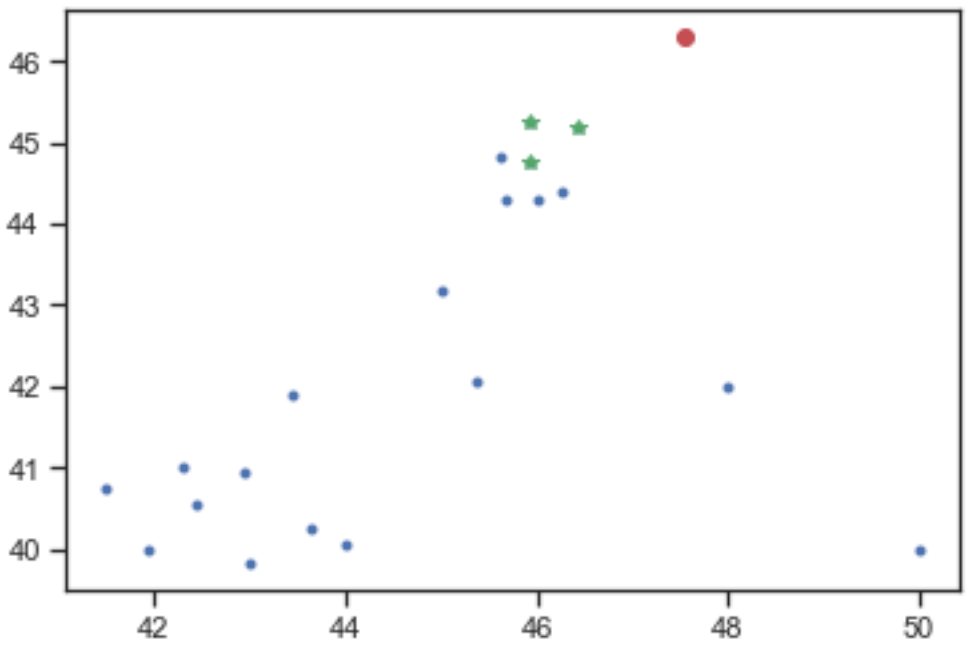


```
Классы, соответствующие K ближайшим соседям:
класс=B, количество элементов=2
класс=C, количество элементов=1

************************************
Проверяемая точка:  [50.0, 47.44]
************************************
Вывод отсортированного списка соседей:
X1=46.44, X2=45.19, y=C, расстояние=4.21
X1=45.94, X2=45.25, y=B, расстояние=4.61
X1=46.25, X2=44.38, y=C, расстояние=4.84
X1=45.94, X2=44.75, y=B, расстояние=4.87
X1=46.0, X2=44.31, y=C, расстояние=5.08
X1=45.63, X2=44.81, y=B, расстояние=5.10
X1=45.69, X2=44.31, y=B, расстояние=5.33
X1=48.0, X2=42.0, y=C, расстояние=5.80
X1=45.0, X2=43.19, y=B, расстояние=6.56
X1=45.38, X2=42.06, y=B, расстояние=7.09
X1=50.0, X2=40.0, y=D, расстояние=7.44
X1=43.44, X2=41.88, y=B, расстояние=8.60
X1=44.0, X2=40.06, y=B, расстояние=9.51
X1=42.94, X2=40.94, y=A, расстояние=9.60
X1=43.63, X2=40.25, y=B, расстояние=9.61
X1=42.31, X2=41.0, y=A, расстояние=10.03
X1=42.44, X2=40.56, y=A, расстояние=10.22
X1=43.0, X2=39.81, y=B, расстояние=10.35
X1=41.5, X2=40.75, y=A, расстояние=10.82
X1=41.94, X2=40.0, y=A, расстояние=10.97

Вывод расстояния для отсортированного списка соседей:
```

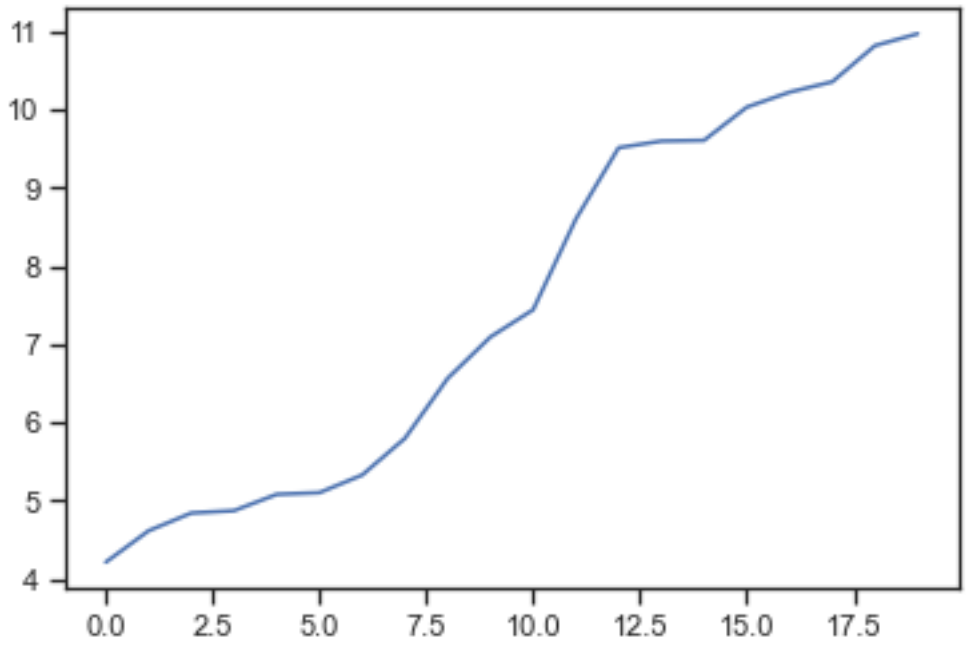


```
Вывод K ближайших соседей:
X1=46.44, X2=45.19, y=C, расстояние=4.21
X1=45.94, X2=45.25, y=B, расстояние=4.61
X1=46.25, X2=44.38, y=C, расстояние=4.84

Визуализация K ближайших соседей:
```

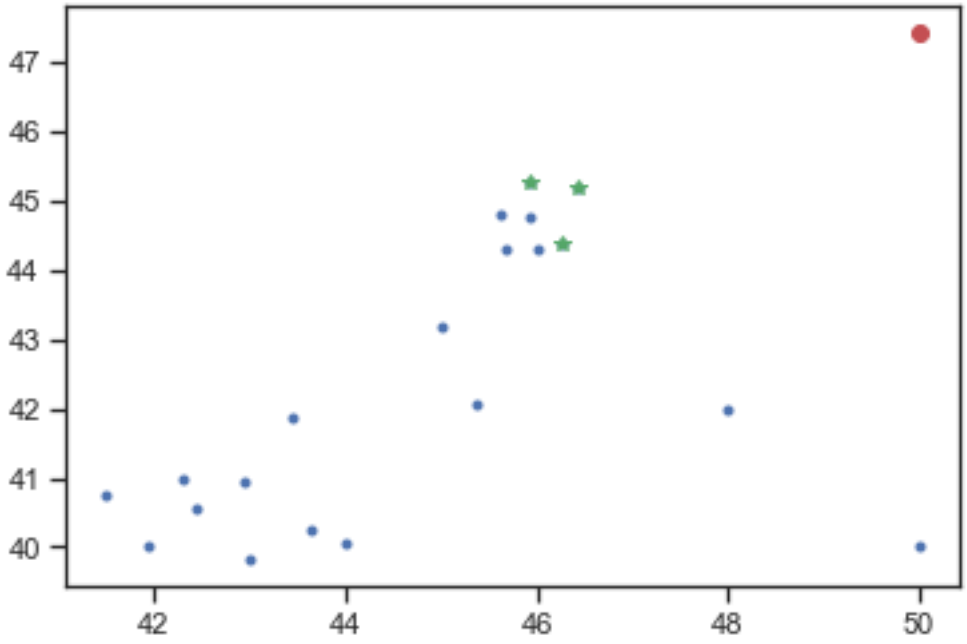


```
Классы, соответствующие K ближайшим соседям:
класс=C, количество элементов=2
класс=B, количество элементов=1
```

```
['B', 'B', 'B', 'B', 'C']
```

```
from sklearn.neighbors import KNeighborsRegressor,
KNeighborsClassifier
```

```
KNeighborsClassifierObj = KNeighborsClassifier(n_neighbors=3)
KNeighborsClassifierObj
```

```
KNeighborsClassifier(n_neighbors=3)
```

```
KNeighborsClassifierObj.fit(data_train[['high','low']],
data_train['y_clas'])
KNeighborsClassifierObj.predict(data_test[['high','low']])
```

```
array(['B', 'B', 'B', 'B', 'C'], dtype=object)
```

```
simple_knn_clas = SimpleKNN()
simple_knn_clas.fit(data_train[['high','low']], data_train['y_clas'])
simple_knn_clas_prediction = simple_knn_clas.predict(K=3, \

prediction_type=PredictionType.CLASSIFICATION, \
                          X_test=data_test[['high','low']], verbose =
False)
np.array(simple_knn_clas_prediction)
```

```
array(['B', 'B', 'B', 'B', 'C'], dtype='<U1')
```

```
KNeighborsRegressorObj = KNeighborsRegressor()
KNeighborsRegressorObj
```

```
KNeighborsRegressor()
```

```
KNeighborsRegressorObj.fit(data_train[['high','low']],
data_train['close'])
KNeighborsRegressorObj.predict(data_test[['high','low']])
```

```
array([45.412, 45.4  , 45.4  , 45.4  , 45.412])
```

```
simple_knn_regr = SimpleKNN()
simple_knn_regr.fit(data_train[['high','low']], data_train['close'])
simple_knn_regr_prediction = simple_knn_regr.predict(K=5, \
                          prediction_type=PredictionType.REGRESSION, \
                          X_test=data_test[['high','low']], verbose =
False)
np.array(simple_knn_regr_prediction)
```

```
array([45.412, 45.4  , 45.4  , 45.4  , 45.412])
```

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from sklearn.datasets import load_iris, load_boston
```

```
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor,
KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import plot_confusion_matrix
from sklearn.metrics import precision_score, recall_score, f1_score,
classification_report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import mean_absolute_error, mean_squared_error,
mean_squared_log_error, median_absolute_error, r2_score
from sklearn.metrics import roc_curve, roc_auc_score
import seaborn as sns
from collections import Counter
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
# Сформируем DataFrame
data = pd.read_csv('WIKI_PRICES1.csv', sep=",")
def regr_to_class(close: float) -> str:
    if close<43:
        result = 1
    elif close<87:
        result = 2
    else:
        result = 3
    return result

# формирование второго целевого признака для классификации
data['y_clas'] = \
data.apply(lambda row: regr_to_class(row['close']),axis=1)
data1 = {'a': [], 'b': []}
data2 = {'c': []}
df = pd.DataFrame(data1)
df1 = pd.DataFrame(data2)
iris = load_iris()
df['a'] = data['high']
df['b'] = data['low']
df1['c'] = data['y_clas']
df = df.astype({'a': float, 'b': float})
df1 = df1.astype({'c': np.int8})
X = df.to_numpy()
y = df1.iloc[:, 0].tolist()
data
```

```
       ticker        date   open    high    low  close      volume  \
0           A  1999-11-18  45.50  50.000  40.00  44.00  44739900.0
1           A  1999-11-19  42.94  43.000  39.81  40.38  10897100.0
2           A  1999-11-22  41.31  44.000  40.06  44.00   4705200.0
3           A  1999-11-23  42.50  43.630  40.25  40.25   4274400.0
4           A  1999-11-24  40.13  41.940  40.00  41.06   3464400.0
...       ...         ...    ...     ...    ...    ...         ...
```

```
500501   AINV  2012-07-18   7.97   8.035   7.89   7.93   1699100.0
500502   AINV  2012-07-19   7.98   8.000   7.87   7.94   1484300.0
500503   AINV  2012-07-20   7.90   7.930   7.76   7.82   1867200.0
500504   AINV  2012-07-23   7.73   7.820   7.59   7.79   2281600.0
500505   AINV  2012-07-24   7.80   7.820   7.55   7.62   1394000.0

        ex-dividend  split_ratio   adj_open   adj_high    adj_low
adj_close  \
0               0.0          1.0  31.041951  34.112034  27.289627
30.018590
1               0.0          1.0  29.295415  29.336350  27.160002
27.548879
2               0.0          1.0  28.183363  30.018590  27.330562
30.018590
3               0.0          1.0  28.995229  29.766161  27.460188
27.460188
4               0.0          1.0  27.378319  28.613174  27.289627
28.012803
...             ...          ...        ...        ...        ...
...
500501          0.0          1.0   4.563940   4.601161   4.518128
4.541034
500502          0.0          1.0   4.569666   4.581119   4.506676
4.546760
500503          0.0          1.0   4.523855   4.541034   4.443685
4.478044
500504          0.0          1.0   4.426506   4.478044   4.346336
4.460864
500505          0.0          1.0   4.466591   4.478044   4.323431
4.363516

        adj_volume  y_clas
0       44739900.0       2
1       10897100.0       1
2        4705200.0       2
3        4274400.0       1
4        3464400.0       1
...            ...     ...
500501   1699100.0       1
500502   1484300.0       1
500503   1867200.0       1
500504   2281600.0       1
500505   1394000.0       1

[500506 rows x 15 columns]
```

```
# И выведем его статистические характеристики
df.describe()
# Для обучения моделей не обязательно создавать DataFrame
# можно использовать массивы numpy
```

```
                   a              b
count  500506.000000  500506.000000
mean       32.004692      31.096170
std        39.937695      38.778618
min         0.015630       0.015630
25%        13.600000      13.100000
50%        24.420000      23.670000
75%        39.750000      38.650000
max      1209.000000    1166.000000
```

```
# Разделение выборки на обучающую и тестовую
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    train_size=0.5,
                                                    random_state=1)
```

```
# Размер обучающей выборки
# iris_X_train.shape, iris_y_train.shape
X_train.shape, len(y_train)
```

```
((250253, 2), 250253)
```

```
# Размер тестовой выборки
# iris_X_test.shape, iris_y_test.shape
X_test.shape, len(y_test)
```

```
((250253, 2), 250253)
```

```
np.unique(y_train)
```

```
array([1, 2, 3])
```

```
np.unique(y_test)
```

```
array([1, 2, 3])
```

```
def class_proportions(array: np.ndarray) -> Dict[int, Tuple[int,
float]]:
    """
    Вычисляет пропорции классов
    array - массив, содержащий метки классов
    """
    # Получение меток классов и количества меток каждого класса
    labels, counts = np.unique(array, return_counts=True)
    # Превращаем количество меток в процент их встречаемости
    # делим количество меток каждого класса на общее количество меток
    counts_perc = counts/array.size
    # Теперь sum(counts_perc)==1.0
    # Создаем результирующий словарь,
    # ключом словаря является метка класса,
    # а значением словаря процент встречаемости метки
    res = dict()
    for label, count2 in zip(labels, zip(counts, counts_perc)):
```

```
            res[label] = count2
    return res

def print_class_proportions(array: np.ndarray):
    """
    Вывод пропорций классов
    """
    proportions = class_proportions(array)
    if len(proportions)>0:
        print('Метка \t Количество \t Процент встречаемости')
    for i in proportions:
        val, val_perc = proportions[i]
        val_perc_100 = round(val_perc * 100, 2)
        print('{} \t {} \t \t {}%'.format(i, val, val_perc_100))

# Для обучающей выборки
Counter(y_train)
```

```
Counter({1: 198436, 2: 42818, 3: 8999})
```

```
# Для тестовой выборки
Counter(y_test)
```

```
Counter({2: 42779, 1: 198303, 3: 9171})
```

```
# 2 ближайших соседа
cl1_1 = KNeighborsClassifier(n_neighbors=2)
cl1_1.fit(X_train, y_train)
target1_1 = cl1_1.predict(X_test)
len(target1_1), target1_1
```

```
(250253, array([2, 1, 1, ..., 1, 1, 1]))
```

```
# 10 ближайших соседей
cl1_2 = KNeighborsClassifier(n_neighbors=10)
cl1_2.fit(X_train, y_train)
target1_2 = cl1_2.predict(X_test)
len(target1_2), target1_2
```

```
(250253, array([2, 1, 1, ..., 1, 1, 1]))
```

```
# iris_y_test - эталонное значение классов из исходной (тестовой)
выборки
# target* - предсказанное значение классов

# 2 ближайших соседа
accuracy_score(y_test, target1_1)
```

```
0.9946933703092471
```

```
def accuracy_score_for_classes(
    y_true: np.ndarray,
```

```
    y_pred: np.ndarray) -> Dict[int, float]:
    """
    Вычисление метрики accuracy для каждого класса
    y_true - истинные значения классов
    y_pred - предсказанные значения классов
    Возвращает словарь: ключ - метка класса,
    значение - Accuracy для данного класса
    """
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = {'t': y_true, 'p': y_pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y_true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp_data_flt = df[df['t']==c]
        # расчет accuracy для заданной метки класса
        temp_acc = accuracy_score(
            temp_data_flt['t'].values,
            temp_data_flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp_acc
    return res

def print_accuracy_score_for_classes(
    y_true: np.ndarray,
    y_pred: np.ndarray):
    """
    Вывод метрики accuracy для каждого класса
    """
    accs = accuracy_score_for_classes(y_true, y_pred)
    if len(accs)>0:
        print('Метка \t Accuracy')
    for i in accs:
        print('{} \t {}'.format(i, accs[i]))

# 2 ближайших соседа
print_accuracy_score_for_classes(y_test, target1_1)
```

```
Метка       Accuracy
1     0.9985275058874551
2     0.9791720236564669
3     0.9841892923345328
```

```
# 10 ближайших соседей
print_accuracy_score_for_classes(y_test, target1_2)
```

```
Метка       Accuracy
1      0.9977357881625594
2      0.9873769840342224
3      0.989859339221459
```

```
# Конвертация целевого признака в бинарный
def convert_target_to_binary(array:np.ndarray, target:int) ->
np.ndarray:
    # Если целевой признак совпадает с указанным, то 1 иначе 0
    res = [1 if x==target else 0 for x in array]
    return res

# Если целевой признак ==2,
# то будем считать этот случай 1 в бинарном признаке
bin_iris_y_train = convert_target_to_binary(y_train, 2)
list(zip(y_train, bin_iris_y_train))[:10]
```

```
[(1, 0),
 (1, 0),
 (2, 1),
 (1, 0),
 (1, 0),
 (1, 0),
 (2, 1),
 (2, 1),
 (2, 1),
 (1, 0)]
```

```
bin_iris_y_test = convert_target_to_binary(y_test, 2)
list(zip(y_test, bin_iris_y_test))[:10]
```

```
[(2, 1),
 (1, 0),
 (1, 0),
 (1, 0),
 (1, 0),
 (1, 0),
 (1, 0),
 (1, 0),
 (2, 1),
 (1, 0)]
```

```
# Конвертация предсказанных признаков
bin_target1_1 = convert_target_to_binary(target1_1, 2)
bin_target1_2 = convert_target_to_binary(target1_2, 2)

balanced_accuracy_score(bin_iris_y_test, bin_target1_1)
```

```
0.9885328678198275
```

```
balanced_accuracy_score(bin_iris_y_test, bin_target1_2)
```

```
0.9923823042538251
```

```
confusion_matrix(bin_iris_y_test, bin_target1_1, labels=[0, 1])
```

```
array([[207037,    437],
       [   891,  41888]], dtype=int64)
```

```
tn, fp, fn, tp = confusion_matrix(bin_iris_y_test,
bin_target1_1).ravel()
tn, fp, fn, tp
```

```
(207037, 437, 891, 41888)
```

```
# Пример для небинарной классификации
confusion_matrix(y_test, target1_1, labels=[0, 1, 2])
```

```
array([[     0,      0,      0],
       [     0, 198011,    292],
       [     0,    856,  41888]], dtype=int64)
```

```
plot_confusion_matrix(cl1_1, X_test, y_test,
                      display_labels=iris.target_names,
cmap=plt.cm.Blues)
```

```
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\utils\deprecation.py:87:
FutureWarning: Function plot_confusion_matrix is deprecated; Function
`plot_confusion_matrix` is deprecated in 1.0 and will be removed in
1.2. Use one of the class methods:
ConfusionMatrixDisplay.from_predictions or
ConfusionMatrixDisplay.from_estimator.
  warnings.warn(msg, category=FutureWarning)
```

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at
0x2931cac5df0>
```

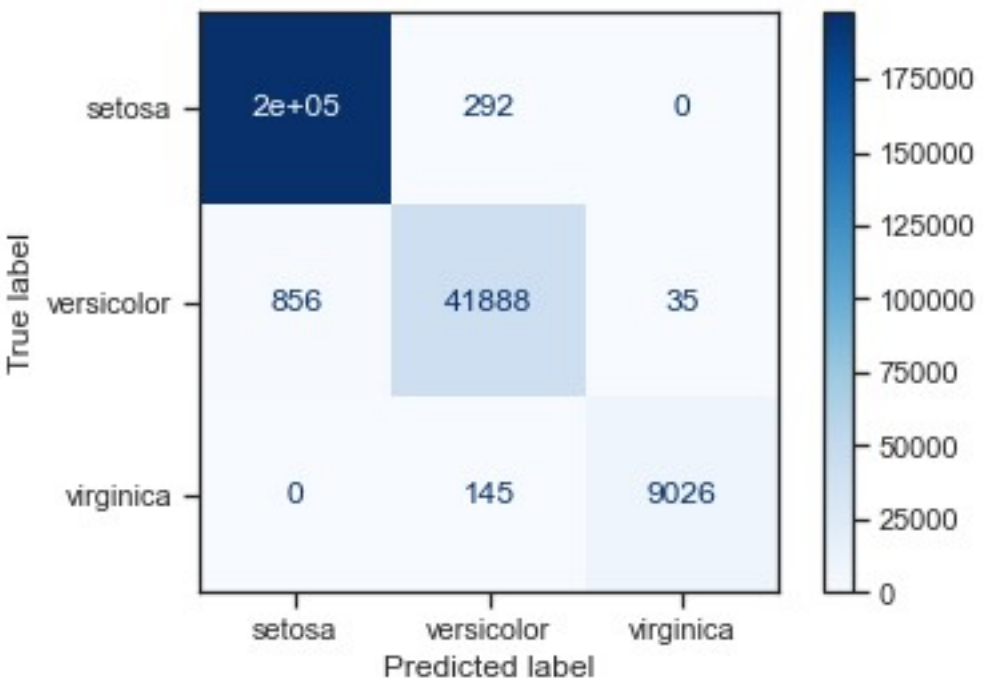


```
plot_confusion_matrix(cl1_1, X_test, y_test,
                      display_labels=iris.target_names,
                      cmap=plt.cm.Blues, normalize='true')
```

```
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\utils\deprecation.py:87:
FutureWarning: Function plot_confusion_matrix is deprecated; Function
`plot_confusion_matrix` is deprecated in 1.0 and will be removed in
1.2. Use one of the class methods:
ConfusionMatrixDisplay.from_predictions or
ConfusionMatrixDisplay.from_estimator.
  warnings.warn(msg, category=FutureWarning)
```

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at
0x2931cac5f10>
```

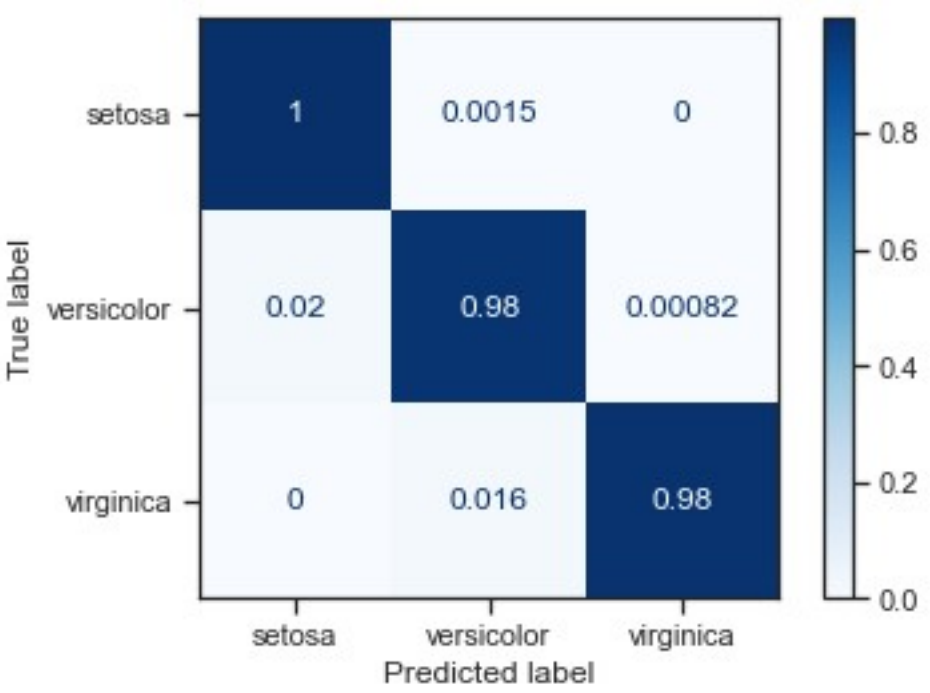


```
fig, ax = plt.subplots(1, 2, sharex='col', sharey='row',
figsize=(15,5))

plot_confusion_matrix(cl1_1, X_test, y_test,
                      display_labels=iris.target_names,
                      cmap=plt.cm.Blues, normalize='true', ax=ax[0])

plot_confusion_matrix(cl1_2, X_test, y_test,
                      display_labels=iris.target_names,
                      cmap=plt.cm.Blues, normalize='true', ax=ax[1])

fig.suptitle('Матрицы ошибок')
ax[0].title.set_text('K=2')
ax[1].title.set_text('K=10')
```

```
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\utils\deprecation.py:87:
FutureWarning: Function plot_confusion_matrix is deprecated; Function
`plot_confusion_matrix` is deprecated in 1.0 and will be removed in
1.2. Use one of the class methods:
ConfusionMatrixDisplay.from_predictions or
ConfusionMatrixDisplay.from_estimator.
  warnings.warn(msg, category=FutureWarning)
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\utils\deprecation.py:87:
FutureWarning: Function plot_confusion_matrix is deprecated; Function
`plot_confusion_matrix` is deprecated in 1.0 and will be removed in
```

```
1.2. Use one of the class methods:
ConfusionMatrixDisplay.from_predictions or
ConfusionMatrixDisplay.from_estimator.
  warnings.warn(msg, category=FutureWarning)
```

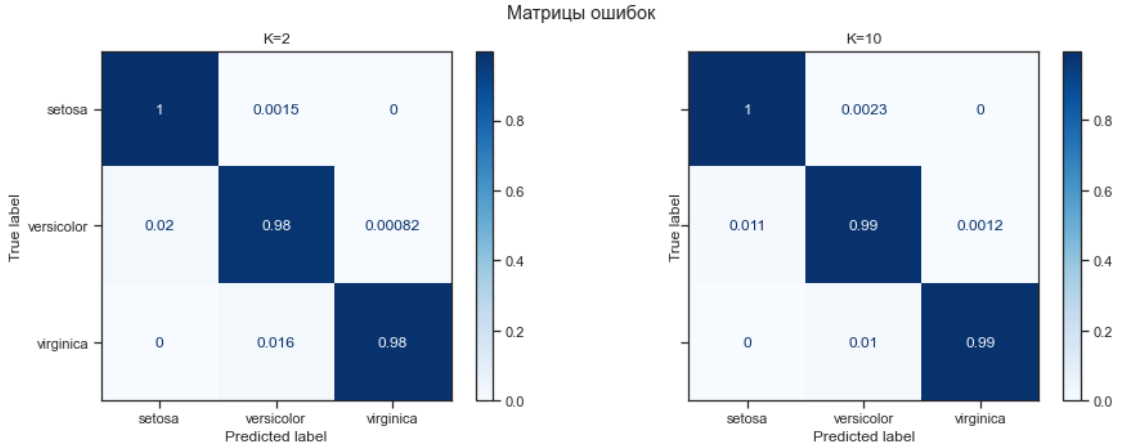


```
# По умолчанию метрики считаются для 1 класса бинарной классификации
# Для 2 ближайших соседей
precision_score(bin_iris_y_test, bin_target1_1),
recall_score(bin_iris_y_test, bin_target1_1)
```

```
(0.9896751329001772, 0.9791720236564669)
```

```
# Для 10 ближайших соседей
precision_score(bin_iris_y_test, bin_target1_2),
recall_score(bin_iris_y_test, bin_target1_2)
```

```
(0.9873308244314065, 0.9873769840342224)
```

```
# Параметры TP, TN, FP, FN считаются как сумма по всем классам
precision_score(y_test, target1_1, average='micro')
```

```
0.9946933703092471
```

```
# Параметры TP, TN, FP, FN считаются отдельно для каждого класса
# и берется среднее значение, дисбаланс классов не учитывается.
precision_score(y_test, target1_1, average='macro')
```

```
0.9938360134175218
```

```
# Параметры TP, TN, FP, FN считаются отдельно для каждого класса
# и берется средневзвешенное значение, дисбаланс классов учитывается
# в виде веса классов (вес - количество истинных значений каждого
класса).
precision_score(y_test, target1_1, average='weighted')
```

```
0.9946826423067406
```

```
f1_score(bin_iris_y_test, bin_target1_2)
```

```
0.9873539036933147
```

```
f1_score(y_test, target1_1, average='micro')
```

```
0.9946933703092471
```

```
f1_score(y_test, target1_1, average='macro')
```

```
0.9905441206452729
```

```
f1_score(y_test, target1_1, average='weighted')
```

```
0.9946803031267678
```

```
classification_report(y_test, target1_1,
                      target_names=iris.target_names,
output_dict=True)
```

```
{'setosa': {'precision': 0.9956956156627293,
  'recall': 0.9985275058874551,
  'f1-score': 0.9971095500667221,
  'support': 198303},
 'versicolor': {'precision': 0.9896751329001772,
  'recall': 0.9791720236564669,
  'f1-score': 0.9843955630757661,
  'support': 42779},
 'virginica': {'precision': 0.996137291689659,
  'recall': 0.9841892923345328,
  'f1-score': 0.9901272487933304,
  'support': 9171},
 'accuracy': 0.9946933703092471,
 'macro avg': {'precision': 0.9938360134175218,
  'recall': 0.9872962739594849,
  'f1-score': 0.9905441206452729,
  'support': 250253},
 'weighted avg': {'precision': 0.9946826423067406,
  'recall': 0.9946933703092471,
  'f1-score': 0.9946803031267678,
  'support': 250253}}
```

```
# Обучим модели на задаче бинарной классифкации,
# чтобы получить вероятности классов

# 2 ближайших соседа
bin_cl1_1 = KNeighborsClassifier(n_neighbors=2)
bin_cl1_1.fit(X_train, bin_iris_y_train)
# предскажем метки классов
bin_cl1_1.predict(X_test)
```

```
array([1, 0, 0, ..., 0, 0, 0])
```

```
# Классы возвращаются в следующем порядке
bin_cl1_1.classes_
```

```
array([0, 1])
```

```
# предскажем вероятности классов
proba_target1_1 = bin_cl1_1.predict_proba(X_test)
len(proba_target1_1), proba_target1_1
```

```
(250253,
 array([[0., 1.],
        [1., 0.],
        [1., 0.],
        ...,
        [1., 0.],
        [1., 0.],
        [1., 0.]]))
```

```
# вероятность единичного (истинного) класса
true_proba_target1_1 = proba_target1_1[:,1]
true_proba_target1_1
```

```
array([1., 0., 0., ..., 0., 0., 0.])
```

```
fpr, tpr, thresholds = roc_curve(bin_iris_y_test,
true_proba_target1_1,
                                 pos_label=1)
fpr, tpr, thresholds
```

```
(array([0.        , 0.0016243 , 0.00475722, 1.        ]),
 array([0.        , 0.97692793, 0.9932911 , 1.        ]),
 array([2. , 1. , 0.5, 0. ]))
```

```
# Отрисовка ROC-кривой
def draw_roc_curve(y_true, y_score, pos_label, average):
    fpr, tpr, thresholds = roc_curve(y_true, y_score,
                                     pos_label=pos_label)
    roc_auc_value = roc_auc_score(y_true, y_score, average=average)
    plt.figure()
    lw = 2
    plt.plot(fpr, tpr, color='darkorange',
             lw=lw, label='ROC curve (area = %0.2f)' % roc_auc_value)
    plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
    plt.xlim([0.0, 1.0])
    plt.ylim([0.0, 1.05])
    plt.xlabel('False Positive Rate')
    plt.ylabel('True Positive Rate')
    plt.title('Receiver operating characteristic example')
    plt.legend(loc="lower right")
    plt.show()
```

```
# Для 2 ближайших соседей
draw_roc_curve(bin_iris_y_test, bin_target1_1, pos_label=1,
average='micro')
```

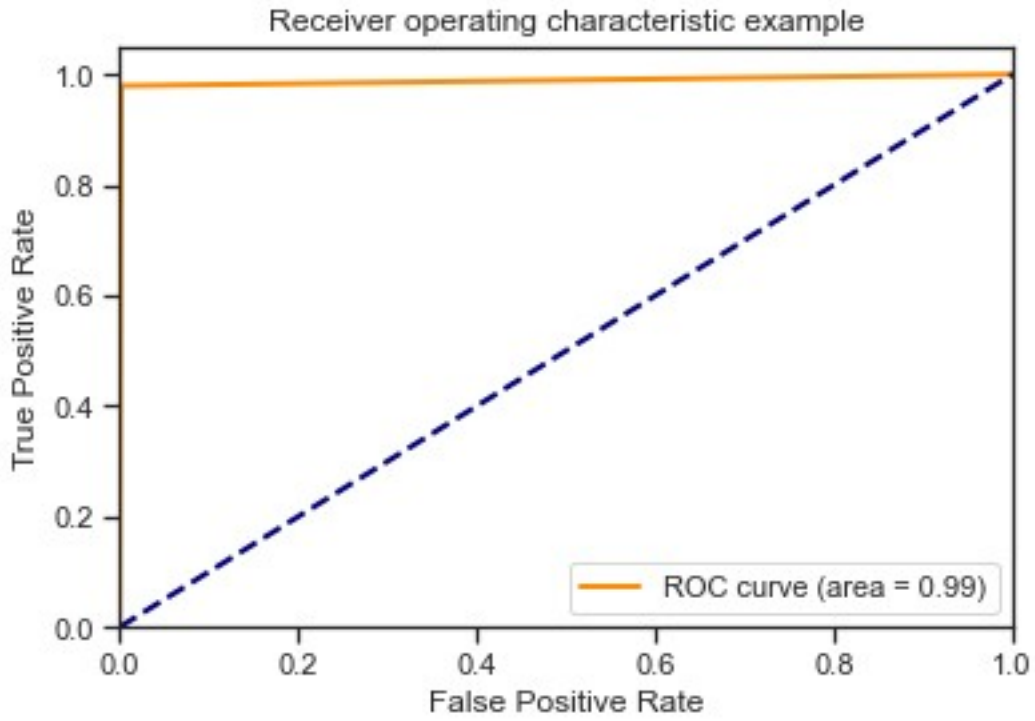


```
# Для 10 ближайших соседей
bin_cl1_2 = KNeighborsClassifier(n_neighbors=10)
bin_cl1_2.fit(X_train, bin_iris_y_train)
proba_target2_1 = bin_cl1_2.predict_proba(X_test)
true_proba_target2_1 = proba_target2_1[:,1]
roc_curve_k10_res = roc_curve(bin_iris_y_test, true_proba_target2_1,
pos_label=1)
roc_curve_k10_res
```

```
(array([0.00000000e+00, 9.15777399e-05, 3.08472387e-04, 8.91677993e-
04,
        1.69659813e-03, 2.51597791e-03, 3.41247578e-03, 4.40537128e-
03,
        5.30186915e-03, 6.20800679e-03, 7.35513848e-03,
1.00000000e+00]),
 array([0.        , 0.96182706, 0.96736717, 0.97543187, 0.98157975,
        0.98683934, 0.99060287, 0.99415601, 0.99691437, 0.99866757,
        0.99955586, 1.        ]),
 array([2. , 1. , 0.9, 0.8, 0.7, 0.6, 0.5, 0.4, 0.3, 0.2, 0.1, 0. ]))
```

```
draw_roc_curve(bin_iris_y_test, true_proba_target2_1, pos_label=1,
average='micro')
```

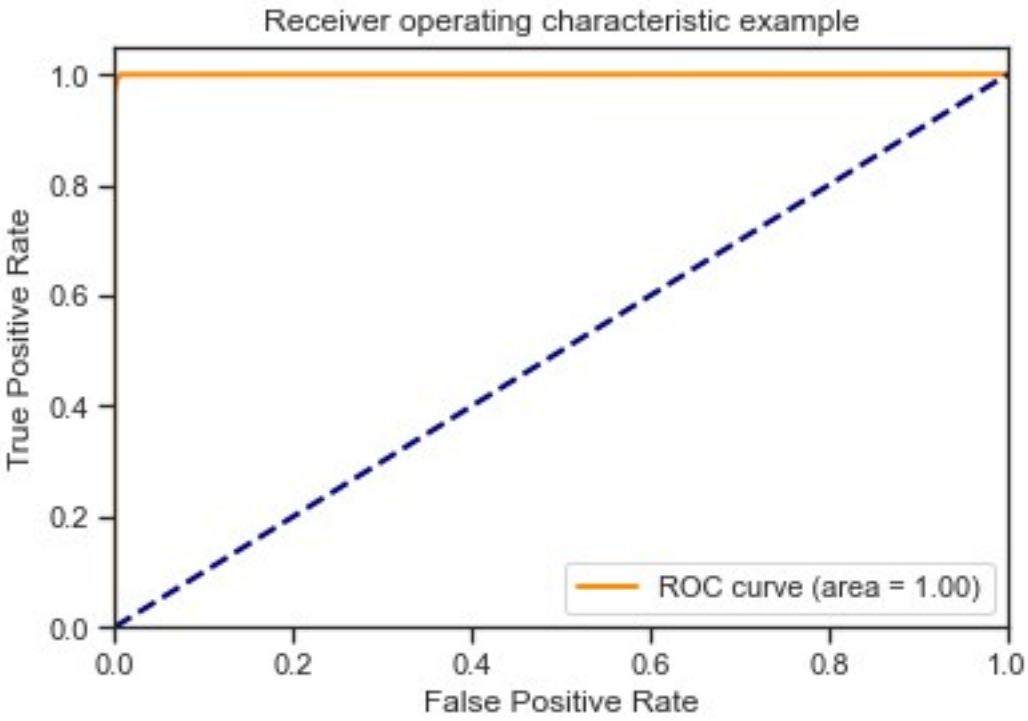


```python
def simple_roc_curve(y_true: np.ndarray, y_score: np.ndarray):
    """
    Простая реализация построения ROC-кривой
    """
    # Результирующие массивы
    tpr_arr = []
    fpr_arr = []
    # Получаем уникальные значения вероятностей
    unique_scores = np.unique(y_score)
    # и сортируем их в обратном порядке
    unique_scores_sorted = np.sort(unique_scores)[::-1]

    # Считаем количество истинных 0 и 1 значений
    # Истинные 1 - это TP+FN
    P = np.sum(y_true > 0)
    # Истинные 0 - это FP+TN
    N = y_true.size - P

    # Внешний цикл по уникальным значениям вероятностей
    for t_cur in  unique_scores_sorted:
        FP, TP = 0, 0
        # Вложенный цикл по всем предсказаниям
        for y, score in zip(y_true, y_score):

            # Если вероятность текущего предсказания больше пороговой
            if score >= t_cur:
                # и истинное значение = 1
                if y > 0:
```

```
                    TP = TP + 1
                else:
                    FP = FP + 1

        # Вычисление значений TPR и FPR для текущего порога
вероятности
        TPR = TP/P
        FPR = FP/N
        # Добавление их в списки
        tpr_arr.append(TPR)
        fpr_arr.append(FPR)

    # Формат вывода совпадает с roc_curve
    return np.array(fpr_arr), np.array(tpr_arr), unique_scores_sorted

simple_roc_curve(np.array(bin_iris_y_test),
np.array(true_proba_target2_1))
```

```
(array([9.15777399e-05, 3.08472387e-04, 8.91677993e-04, 1.69659813e-
03,
        2.51597791e-03, 3.41247578e-03, 4.40537128e-03, 5.30186915e-
03,
        6.20800679e-03, 7.35513848e-03, 1.00000000e+00]),
 array([0.96182706, 0.96736717, 0.97543187, 0.98157975, 0.98683934,
        0.99060287, 0.99415601, 0.99691437, 0.99866757, 0.99955586,
        1.        ]),
 array([1. , 0.9, 0.8, 0.7, 0.6, 0.5, 0.4, 0.3, 0.2, 0.1, 0. ]))
```

```
# Отрисовка двух ROC-кривых
def draw_roc_curve_2(y_true, y_score, pos_label, average):
    fpr, tpr, thresholds = roc_curve(y_true, y_score,
                                     pos_label=pos_label)
    # стандартный метод из sklearn
    roc_auc_value = roc_auc_score(y_true, y_score, average=average)
    # собственная реализация
    fpr2, tpr2, thresholds2 = simple_roc_curve(y_true, y_score)

    plt.figure()
    lw = 2
    plt.plot(fpr, tpr, color='darkorange',
             lw=lw, label='ROC curve (area = %0.2f)' % roc_auc_value)
    plt.plot(fpr2, tpr2, color='green', alpha=0.5)
    plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
    plt.xlim([0.0, 1.0])
    plt.ylim([0.0, 1.05])
    plt.xlabel('False Positive Rate')
    plt.ylabel('True Positive Rate')
    plt.title('Receiver operating characteristic example')
    plt.legend(loc="lower right")
    plt.show()
```

```
draw_roc_curve_2(np.array(bin_iris_y_test),
np.array(true_proba_target1_1), pos_label=1, average='micro')
```

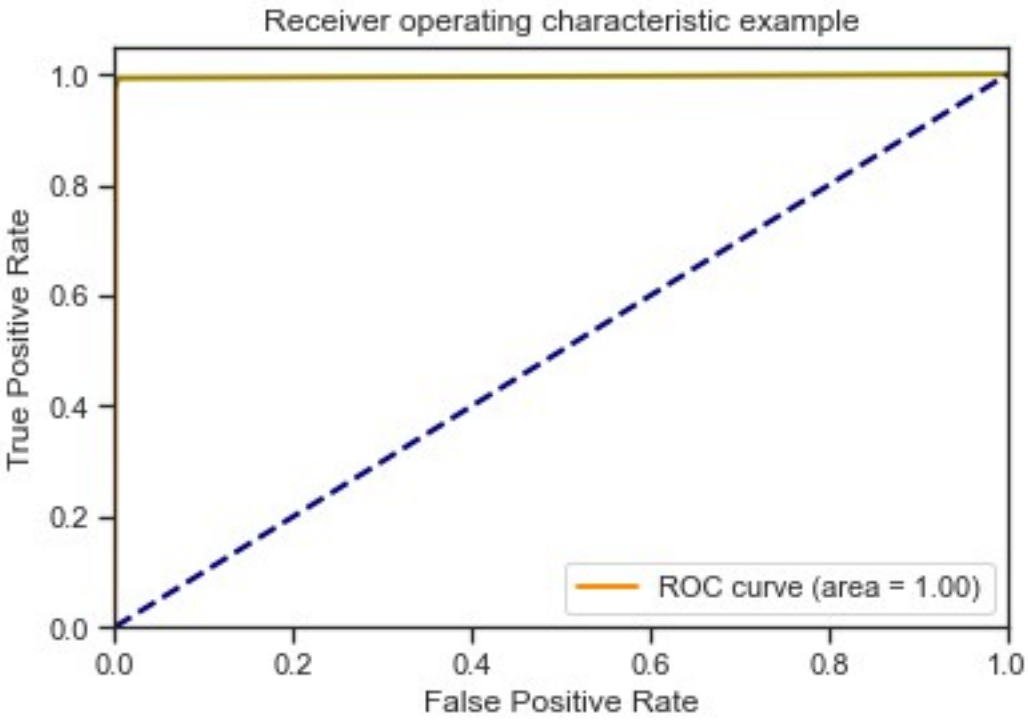


```
draw_roc_curve_2(np.array(bin_iris_y_test),
np.array(true_proba_target2_1), pos_label=1, average='micro')
```

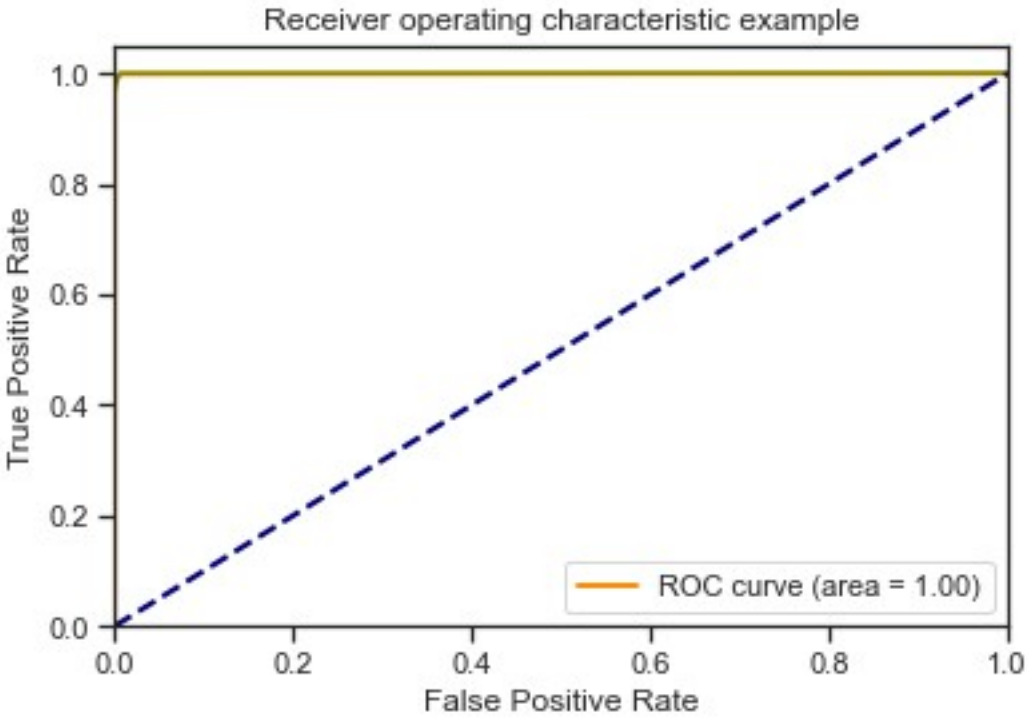

```
# Для 10 ближайших соседей
from sklearn.linear_model import LogisticRegression
lr = LogisticRegression()
lr.fit(X_train, bin_iris_y_train)
proba_lr = lr.predict_proba(X_test)
true_proba_lr = proba_lr[:,1]
roc_curve_lr_res = roc_curve(bin_iris_y_test, true_proba_lr,
pos_label=1)
roc_curve_lr_res
```

```
(array([0.00000000e+00, 4.81988105e-06, 4.68010450e-03, ...,
        9.99980720e-01, 9.99980720e-01, 1.00000000e+00]),
 array([0.        , 0.        , 0.        , ..., 0.99992987, 1.
,
        1.        ]),
 array([2.00000000e+00, 1.00000000e+00, 9.89203685e-01, ...,
        3.95179954e-03, 9.51726033e-04, 1.42345234e-04]))
```

```
from IPython.display import Image
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_iris, load_boston
from sklearn.neighbors import KNeighborsRegressor,
KNeighborsClassifier
from sklearn.model_selection import cross_val_score, cross_validate
from sklearn.model_selection import KFold, RepeatedKFold, LeaveOneOut,
LeavePOut, ShuffleSplit, StratifiedKFold
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score,
classification_report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import mean_absolute_error, mean_squared_error,
mean_squared_log_error, median_absolute_error, r2_score
from sklearn.metrics import roc_curve, roc_auc_score
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.model_selection import learning_curve, validation_curve
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

```
data = pd.read_csv('WIKI_PRICES1.csv', sep=",")
data1 = {'a': [], 'b': []}
data2 = {'c': []}
df = pd.DataFrame(data1)
df1 = pd.DataFrame(data2)
iris = load_iris()
df['a'] = data['high']
df['b'] = data['low']
df1['c'] = data['close']
```

```
df = df.astype({'a': float, 'b': float})
df1 = df1.astype({'c': np.int8})
X = df.to_numpy()
y = df1.iloc[:, 0].tolist()

# Разделение выборки на обучающую и тестовую
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    train_size=0.5,
                                                    random_state=1)

# В моделях k-ближайших соседей большое значение k
# ведёт к большому смещению и низкой дисперсии (недообучению)
# 70 ближайших соседей
cl1_1 = KNeighborsClassifier(n_neighbors=70)
cl1_1.fit(X_train, y_train)
target1_0 = cl1_1.predict(X_train)
target1_1 = cl1_1.predict(X_test)
accuracy_score(y_train, target1_0), accuracy_score(y_test, target1_1)
```

```
(0.7787119435131646, 0.7702604963776658)
```

```
# 5 ближайших соседей
cl1_2 = KNeighborsClassifier(n_neighbors=5)
cl1_2.fit(X_train, y_train)
target1_0 = cl1_2.predict(X_train)
target1_1 = cl1_2.predict(X_test)
accuracy_score(y_train, target1_0), accuracy_score(y_test, target1_1)
```

```
(0.8212049406001127, 0.7483226974302006)
```

```
# 5 ближайших соседей
cl1_2 = KNeighborsClassifier(n_neighbors=5)
cl1_2.fit(X_train, y_train)
target1_0 = cl1_2.predict(X_train)
target1_1 = cl1_2.predict(X_test)
accuracy_score(y_train, target1_0), accuracy_score(y_test, target1_1)
```

```
(0.8212049406001127, 0.7483226974302006)
```

```
# 1 ближайший сосед - "условное" переобучение
cl1_2 = KNeighborsClassifier(n_neighbors=1)
cl1_2.fit(X_train, y_train)
target1_0 = cl1_2.predict(X_train)
target1_1 = cl1_2.predict(X_test)
accuracy_score(y_train, target1_0), accuracy_score(y_test, target1_1)
```

```
(0.9356051675704188, 0.7249383623772742)
```

```
scores = cross_val_score(KNeighborsClassifier(n_neighbors=2),
                         X, y, cv=3)

# Значение метрики accuracy для 3 фолдов
scores
```

```
array([0.71706946, 0.71726556, 0.73449816])
```

```
# Усредненное значение метрики accuracy для 3 фолдов
np.mean(scores)
```

```
0.7229443920251398
```

```
# использование метрики f1
scores = cross_val_score(KNeighborsClassifier(n_neighbors=2),
                         X, y, cv=3,
                         scoring='f1_weighted')
scores, np.mean(scores)
```

```
(array([0.71752624, 0.71676814, 0.73396968]), 0.7227546878077792)
```

```
scoring = {'precision': 'precision_weighted',
           'recall': 'recall_weighted',
           'f1': 'f1_weighted'}

scores = cross_validate(KNeighborsClassifier(n_neighbors=2),
                        X, y, scoring=scoring,
                        cv=3, return_train_score=True)
scores
```

```
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
```

```
{'fit_time': array([0.34757686, 0.35644412, 0.36185503]),
 'score_time': array([3.66560793, 4.21687341, 3.71113873]),
 'test_precision': array([0.71869359, 0.71684451, 0.73408341]),
 'train_precision': array([0.83993227, 0.84254582, 0.83841761]),
 'test_recall': array([0.71706946, 0.71726556, 0.73449816]),
 'train_recall': array([0.84003057, 0.84266838, 0.83856553]),
 'test_f1': array([0.71752624, 0.71676814, 0.73396968]),
 'train_f1': array([0.83976023, 0.84241472, 0.83831462])}
```

```
# Возвращаются индексы элементов
X1 = ["a", "b", "c"]
kf = KFold(n_splits=3)
```

```
for train, test in kf.split(X1):
    print("%s %s" % (train, test))
```

```
[1 2] [0]
[0 2] [1]
[0 1] [2]
```

```
X1 = range(12)
kf = KFold(n_splits=3)
for train, test in kf.split(X1):
    print("%s %s" % (train, test))
```

```
[ 4  5  6  7  8  9 10 11] [0 1 2 3]
[ 0  1  2  3  8  9 10 11] [4 5 6 7]
[0 1 2 3 4 5 6 7] [ 8  9 10 11]
```

```
kf = KFold(n_splits=5)
scores = cross_val_score(KNeighborsClassifier(n_neighbors=2),
                         X, y, scoring='f1_weighted',
                         cv=kf)
scores
```

```
array([0.68366378, 0.77166522, 0.69918831, 0.72099076, 0.74398748])
```

```
kf = KFold(n_splits=5)
scores = cross_validate(KNeighborsClassifier(n_neighbors=2),
                        X, y, scoring=scoring,
                        cv=kf, return_train_score=True)
scores
```

```
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Recall is ill-defined
and being set to 0.0 in labels with no true samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
```

```
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Recall is ill-defined
and being set to 0.0 in labels with no true samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Recall is ill-defined
and being set to 0.0 in labels with no true samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Precision is ill-
defined and being set to 0.0 in labels with no predicted samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\metrics\
_classification.py:1318: UndefinedMetricWarning: Recall is ill-defined
and being set to 0.0 in labels with no true samples. Use
`zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))

{'fit_time': array([0.42319226, 0.42117333, 0.42702055, 0.4431479 ,
0.4351244 ]),
 'score_time': array([2.26196647, 2.20793629, 2.32695794, 2.19190335,
2.42379904]),
 'test_precision': array([0.68647215, 0.77193347, 0.69933414,
0.7211375 , 0.74425084]),
 'train_precision': array([0.84359613, 0.83104049, 0.84294598,
0.84130726, 0.83333579]),
```

```
 'test_recall': array([0.68266368, 0.77207021, 0.69971329, 0.72150128,
0.74448807]),
 'train_recall': array([0.84377529, 0.8312134 , 0.84312134,
0.84149798, 0.83349109]),
 'test_f1': array([0.68366378, 0.77166522, 0.69918831, 0.72099076,
0.74398748]),
 'train_f1': array([0.84351657, 0.83094216, 0.84286511, 0.84124014,
0.83323878])}
```

```
X1 = range(12)
kf = RepeatedKFold(n_splits=3, n_repeats=2)
for train, test in kf.split(X1):
    print("%s %s" % (train, test))
```

```
[ 2  3  5  6  7  8 10 11] [0 1 4 9]
[ 0  1  4  6  7  8  9 11] [ 2  3  5 10]
[ 0  1  2  3  4  5  9 10] [ 6  7  8 11]
[0 1 2 3 4 5 7 8] [ 6  9 10 11]
[ 1  5  6  7  8  9 10 11] [0 2 3 4]
[ 0  2  3  4  6  9 10 11] [1 5 7 8]
```

```
X1 = range(12)
# Эквивалент KFold(n_splits=n)
kf = LeaveOneOut()
for train, test in kf.split(X1):
    print("%s %s" % (train, test))
```

```
[ 1  2  3  4  5  6  7  8  9 10 11] [0]
[ 0  2  3  4  5  6  7  8  9 10 11] [1]
[ 0  1  3  4  5  6  7  8  9 10 11] [2]
[ 0  1  2  4  5  6  7  8  9 10 11] [3]
[ 0  1  2  3  5  6  7  8  9 10 11] [4]
[ 0  1  2  3  4  6  7  8  9 10 11] [5]
[ 0  1  2  3  4  5  7  8  9 10 11] [6]
[ 0  1  2  3  4  5  6  8  9 10 11] [7]
[ 0  1  2  3  4  5  6  7  9 10 11] [8]
[ 0  1  2  3  4  5  6  7  8 10 11] [9]
[ 0  1  2  3  4  5  6  7  8  9 11] [10]
[ 0  1  2  3  4  5  6  7  8  9 10] [11]
```

```
X1 = range(12)
# Эквивалент KFold(n_splits=n)
kf = LeavePOut(2)
for train, test in kf.split(X1):
    print("%s %s" % (train, test))
```

```
[ 2  3  4  5  6  7  8  9 10 11] [0 1]
[ 1  3  4  5  6  7  8  9 10 11] [0 2]
[ 1  2  4  5  6  7  8  9 10 11] [0 3]
[ 1  2  3  5  6  7  8  9 10 11] [0 4]
[ 1  2  3  4  6  7  8  9 10 11] [0 5]
```

```
[ 1  2  3  4  5  7  8  9 10 11] [0 6]
[ 1  2  3  4  5  6  8  9 10 11] [0 7]
[ 1  2  3  4  5  6  7  9 10 11] [0 8]
[ 1  2  3  4  5  6  7  8 10 11] [0 9]
[ 1  2  3  4  5  6  7  8  9 11] [ 0 10]
[ 1  2  3  4  5  6  7  8  9 10] [ 0 11]
[ 0  3  4  5  6  7  8  9 10 11] [1 2]
[ 0  2  4  5  6  7  8  9 10 11] [1 3]
[ 0  2  3  5  6  7  8  9 10 11] [1 4]
[ 0  2  3  4  6  7  8  9 10 11] [1 5]
[ 0  2  3  4  5  7  8  9 10 11] [1 6]
[ 0  2  3  4  5  6  8  9 10 11] [1 7]
[ 0  2  3  4  5  6  7  9 10 11] [1 8]
[ 0  2  3  4  5  6  7  8 10 11] [1 9]
[ 0  2  3  4  5  6  7  8  9 11] [ 1 10]
[ 0  2  3  4  5  6  7  8  9 10] [ 1 11]
[ 0  1  4  5  6  7  8  9 10 11] [2 3]
[ 0  1  3  5  6  7  8  9 10 11] [2 4]
[ 0  1  3  4  6  7  8  9 10 11] [2 5]
[ 0  1  3  4  5  7  8  9 10 11] [2 6]
[ 0  1  3  4  5  6  8  9 10 11] [2 7]
[ 0  1  3  4  5  6  7  9 10 11] [2 8]
[ 0  1  3  4  5  6  7  8 10 11] [2 9]
[ 0  1  3  4  5  6  7  8  9 11] [ 2 10]
[ 0  1  3  4  5  6  7  8  9 10] [ 2 11]
[ 0  1  2  5  6  7  8  9 10 11] [3 4]
[ 0  1  2  4  6  7  8  9 10 11] [3 5]
[ 0  1  2  4  5  7  8  9 10 11] [3 6]
[ 0  1  2  4  5  6  8  9 10 11] [3 7]
[ 0  1  2  4  5  6  7  9 10 11] [3 8]
[ 0  1  2  4  5  6  7  8 10 11] [3 9]
[ 0  1  2  4  5  6  7  8  9 11] [ 3 10]
[ 0  1  2  4  5  6  7  8  9 10] [ 3 11]
[ 0  1  2  3  6  7  8  9 10 11] [4 5]
[ 0  1  2  3  5  7  8  9 10 11] [4 6]
[ 0  1  2  3  5  6  8  9 10 11] [4 7]
[ 0  1  2  3  5  6  7  9 10 11] [4 8]
[ 0  1  2  3  5  6  7  8 10 11] [4 9]
[ 0  1  2  3  5  6  7  8  9 11] [ 4 10]
[ 0  1  2  3  5  6  7  8  9 10] [ 4 11]
[ 0  1  2  3  4  7  8  9 10 11] [5 6]
[ 0  1  2  3  4  6  8  9 10 11] [5 7]
[ 0  1  2  3  4  6  7  9 10 11] [5 8]
[ 0  1  2  3  4  6  7  8 10 11] [5 9]
[ 0  1  2  3  4  6  7  8  9 11] [ 5 10]
[ 0  1  2  3  4  6  7  8  9 10] [ 5 11]
[ 0  1  2  3  4  5  8  9 10 11] [6 7]
[ 0  1  2  3  4  5  7  9 10 11] [6 8]
[ 0  1  2  3  4  5  7  8 10 11] [6 9]
[ 0  1  2  3  4  5  7  8  9 11] [ 6 10]
```

```
[ 0  1  2  3  4  5  7  8  9 10] [ 6 11]
[ 0  1  2  3  4  5  6  9 10 11] [7 8]
[ 0  1  2  3  4  5  6  8 10 11] [7 9]
[ 0  1  2  3  4  5  6  8  9 11] [ 7 10]
[ 0  1  2  3  4  5  6  8  9 10] [ 7 11]
[ 0  1  2  3  4  5  6  7 10 11] [8 9]
[ 0  1  2  3  4  5  6  7  9 11] [ 8 10]
[ 0  1  2  3  4  5  6  7  9 10] [ 8 11]
[ 0  1  2  3  4  5  6  7  8 11] [ 9 10]
[ 0  1  2  3  4  5  6  7  8 10] [ 9 11]
[0 1 2 3 4 5 6 7 8 9] [10 11]
```

```
X1 = range(12)
# Эквивалент KFold(n_splits=n)
kf = ShuffleSplit(n_splits=5, test_size=0.25)
for train, test in kf.split(X1):
    print("%s %s" % (train, test))
```

```
[ 3  6  4 10  7  1 11  8  9] [0 5 2]
[ 7  9  8  2 10  6  3  4  1] [ 0  5 11]
[ 0 11  3  6  7  2  5  8  1] [10  4  9]
[ 6 11  2 10  1  8  4  9  5] [0 3 7]
[ 2  8  5  6  0  7  9 10  3] [ 1  4 11]
```

```
X1 = np.ones(10)
y1 = [0, 0, 0, 1, 1, 1, 1, 1, 1, 1]
skf = StratifiedKFold(n_splits=3)
for train, test in skf.split(X1, y1):
    print("%s %s" % (train, test))
```

```
[1 2 6 7 8 9] [0 3 4 5]
[0 2 3 4 5 8 9] [1 6 7]
[0 1 3 4 5 6 7] [2 8 9]
```

```
X1 = np.ones(10)
y1 = [0, 0, 0, 1, 1, 1, 1, 1, 1, 1]
skf = StratifiedKFold(n_splits=5)
for train, test in skf.split(X1, y1):
    print("%s %s" % (train, test))
```

```
[1 2 4 5 6 7 8 9] [0 3]
[0 2 3 5 6 7 8 9] [1 4]
[0 1 3 4 6 7 8 9] [2 5]
[0 1 2 3 4 5 8 9] [6 7]
[0 1 2 3 4 5 6 7] [8 9]
```

```
C:\Users\Admин\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\model_selection\_split.py:676:
UserWarning: The least populated class in y has only 3 members, which
is less than n_splits=5.
  warnings.warn(
```

```
X1 = np.ones(10)
y1 = [0, 0, 0, 0, 1, 0, 1, 1, 1, 1]
skf = StratifiedKFold(n_splits=5)
for train, test in skf.split(X1, y1):
    print("%s %s" % (train, test))
```

```
[1 2 3 5 6 7 8 9] [0 4]
[0 2 3 4 5 7 8 9] [1 6]
[0 1 3 4 5 6 8 9] [2 7]
[0 1 2 4 5 6 7 9] [3 8]
[0 1 2 3 4 6 7 8] [5 9]
```

```
n_range = np.array(range(5,55,5))
tuned_parameters = [{'n_neighbors': n_range}]
tuned_parameters
```

```
[{'n_neighbors': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50])}]
```

```
%%time
clf_gs = GridSearchCV(KNeighborsClassifier(), tuned_parameters, cv=5,
scoring='accuracy')
clf_gs.fit(X_train, y_train)
```

```
Wall time: 1min 18s
```

```
GridSearchCV(cv=5, estimator=KNeighborsClassifier(),
             param_grid=[{'n_neighbors': array([ 5, 10, 15, 20, 25,
30, 35, 40, 45, 50])}],
             scoring='accuracy')
```

```
clf_gs.cv_results_
```

```
{'mean_fit_time': array([0.21684804, 0.22814598, 0.22043943,
0.27976251, 0.25433254,
        0.24078159, 0.24881349, 0.24733958, 0.22939444, 0.22700768]),
 'std_fit_time': array([0.00161345, 0.00993246, 0.00173374,
0.04046872, 0.04037733,
        0.0311306 , 0.03677876, 0.03107488, 0.0100987 , 0.00851473]),
 'mean_score_time': array([1.03345842, 1.10205092, 1.14436364,
1.37666903, 1.31142654,
        1.37678051, 1.44212422, 1.47185993, 1.55803823, 1.46546044]),
 'std_score_time': array([0.0137137 , 0.0351537 , 0.04652715,
0.1496858 , 0.06285649,
        0.1305565 , 0.11634956, 0.10507524, 0.07859415, 0.03810133]),
 'param_n_neighbors': masked_array(data=[5, 10, 15, 20, 25, 30, 35,
40, 45, 50],
              mask=[False, False, False, False, False, False, False,
False,
                    False, False],
        fill_value='?',
             dtype=object),
 'params': [{'n_neighbors': 5},
```

```
  {'n_neighbors': 10},
  {'n_neighbors': 15},
  {'n_neighbors': 20},
  {'n_neighbors': 25},
  {'n_neighbors': 30},
  {'n_neighbors': 35},
  {'n_neighbors': 40},
  {'n_neighbors': 45},
  {'n_neighbors': 50}],
 'split0_test_score': array([0.75265229, 0.75914567, 0.76360113,
0.76501968, 0.76583884,
        0.76633833, 0.76685781, 0.76807656, 0.76809654, 0.76871591]),
 'split1_test_score': array([0.75003496, 0.76038441, 0.76595872,
0.7671575 , 0.76883579,
        0.76919542, 0.76961499, 0.77155302, 0.77149308, 0.77195261]),
 'split2_test_score': array([0.74947553, 0.75948532, 0.76495974,
0.76667799, 0.76875587,
        0.76883579, 0.77001459, 0.77143314, 0.7723522 , 0.77251204]),
 'split3_test_score': array([0.74967033, 0.75858142, 0.7630969 ,
0.7645954 , 0.76781219,
        0.76597403, 0.76725275, 0.76801199, 0.76899101, 0.76899101]),
 'split4_test_score': array([0.74455544, 0.75546454, 0.76045954,
0.76067932, 0.76341658,
        0.76535465, 0.76563437, 0.76595405, 0.76735265, 0.76637363]),
 'mean_test_score': array([0.74927771, 0.75861227, 0.76361521,
0.76482598, 0.76693185,
        0.76713964, 0.7678749 , 0.76900575, 0.7696571 , 0.76970904]),
 'std_test_score': array([0.00262505, 0.00167907, 0.00187227,
0.00228698, 0.00206295,
        0.00156781, 0.00167617, 0.00217001, 0.0019403 , 0.00225908]),
 'rank_test_score': array([10,  9,  8,  7,  6,  5,  4,  3,  2,  1])}
```

```
# Лучшая модель
clf_gs.best_estimator_
```

```
KNeighborsClassifier(n_neighbors=50)
```

```
# Лучшее значение метрики
clf_gs.best_score_
```

```
0.7697090382395372
```

```
# Лучшее значение параметров
clf_gs.best_params_
```

```
{'n_neighbors': 50}
```

```
# Изменение качества на тестовой выборке в зависимости от K-соседей
plt.plot(n_range, clf_gs.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x2931cb06760>]
```

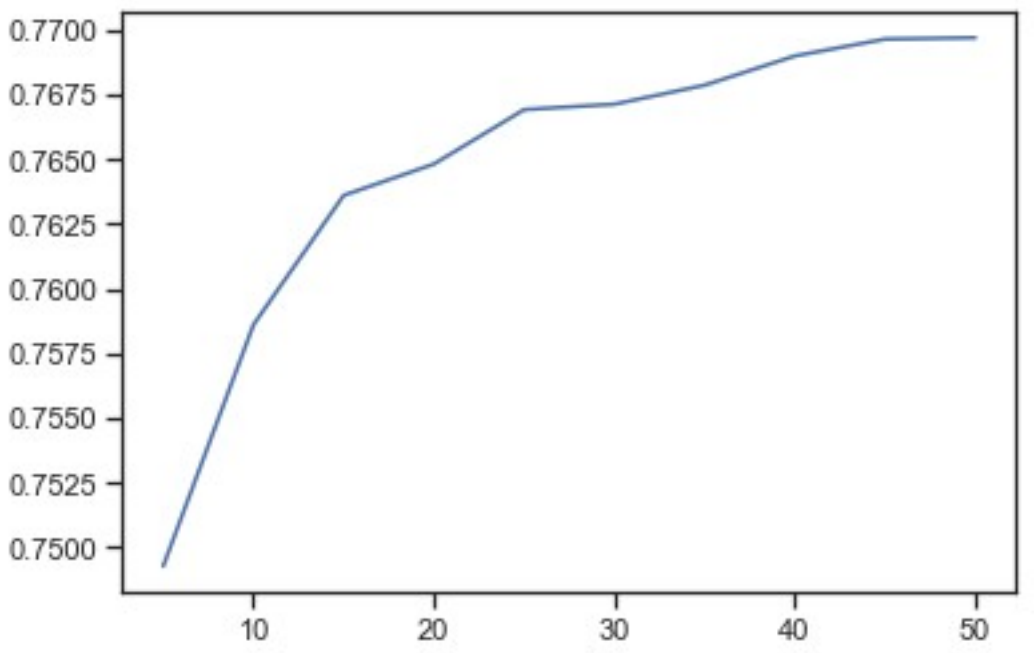


```
%%time
clf_rs = RandomizedSearchCV(KNeighborsClassifier(), tuned_parameters,
cv=5, scoring='accuracy')
clf_rs.fit(X_train, y_train)
```

```
Wall time: 1min 17s
```

```
RandomizedSearchCV(cv=5, estimator=KNeighborsClassifier(),
                   param_distributions=[{'n_neighbors': array([ 5, 10,
15, 20, 25, 30, 35, 40, 45, 50])}],
                   scoring='accuracy')
```

```
# В данном случае оба способа нашли одинаковое решение
clf_rs.best_score_, clf_rs.best_params_
```

```
(0.7697090382395372, {'n_neighbors': 50})
```

```
clf_gs.best_score_, clf_gs.best_params_
```

```
(0.7697090382395372, {'n_neighbors': 50})
```

```
# Изменение качества на тестовой выборке в зависимости от K-соседей
plt.plot(n_range, clf_rs.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x29325f6e700>]
```

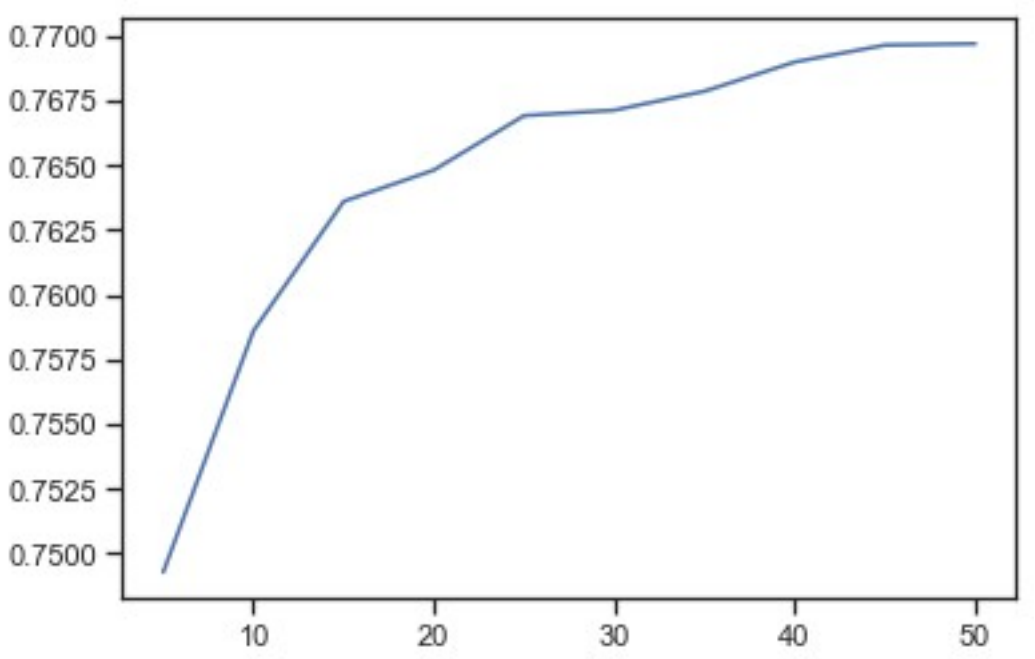


```
def plot_learning_curve(estimator, title, X, y, ylim=None, cv=None,
                        n_jobs=None, train_sizes=np.linspace(.1, 1.0,
5)):
    """
    Generate a simple plot of the test and training learning curve.

    Parameters
    ----------
    estimator : object type that implements the "fit" and "predict"
methods
        An object of that type which is cloned for each validation.

    title : string
        Title for the chart.

    X : array-like, shape (n_samples, n_features)
        Training vector, where n_samples is the number of samples and
        n_features is the number of features.

    y : array-like, shape (n_samples) or (n_samples, n_features),
optional
        Target relative to X for classification or regression;
        None for unsupervised learning.

    ylim : tuple, shape (ymin, ymax), optional
        Defines minimum and maximum yvalues plotted.

    cv : int, cross-validation generator or an iterable, optional
        Determines the cross-validation splitting strategy.
```

```
        Possible inputs for cv are:
          - None, to use the default 3-fold cross-validation,
          - integer, to specify the number of folds.
          - :term:`CV splitter`,
          - An iterable yielding (train, test) splits as arrays of
indices.

        For integer/None inputs, if ``y`` is binary or multiclass,
        :class:`StratifiedKFold` used. If the estimator is not a
classifier
        or if ``y`` is neither binary nor multiclass, :class:`KFold`
is used.

        Refer :ref:`User Guide <cross_validation>` for the various
        cross-validators that can be used here.

    n_jobs : int or None, optional (default=None)
        Number of jobs to run in parallel.
        ``None`` means 1 unless in a :obj:`joblib.parallel_backend`
context.
        ``-1`` means using all processors. See :term:`Glossary
<n_jobs>`
        for more details.

    train_sizes : array-like, shape (n_ticks,), dtype float or int
        Relative or absolute numbers of training examples that will be
used to
        generate the learning curve. If the dtype is float, it is
regarded as a
        fraction of the maximum size of the training set (that is
determined
        by the selected validation method), i.e. it has to be within
(0, 1].
        Otherwise it is interpreted as absolute sizes of the training
sets.
        Note that for classification the number of samples usually
have to
        be big enough to contain at least one sample from each class.
        (default: np.linspace(0.1, 1.0, 5))
    """
    plt.figure()
    plt.title(title)
    if ylim is not None:
        plt.ylim(*ylim)
    plt.xlabel("Training examples")
    plt.ylabel("Score")
    train_sizes, train_scores, test_scores = learning_curve(
        estimator, X, y, cv=cv, n_jobs=n_jobs,
train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
```

```
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    plt.grid()

    plt.fill_between(train_sizes, train_scores_mean -
train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.3,
                     color="r")
    plt.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1,
color="g")
    plt.plot(train_sizes, train_scores_mean, 'o-', color="r",
             label="Training score")
    plt.plot(train_sizes, test_scores_mean, 'o-', color="g",
             label="Cross-validation score")

    plt.legend(loc="best")
    return plt

plot_learning_curve(KNeighborsClassifier(n_neighbors=5),
'n_neighbors=5',
                    X_train, y_train, cv=20)
```

```
C:\Users\Admin\AppData\Local\Packages\
PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\LocalCache\local-
packages\Python39\site-packages\sklearn\model_selection\_split.py:676:
UserWarning: The least populated class in y has only 8 members, which
is less than n_splits=20.
  warnings.warn(
```

```
<module 'matplotlib.pyplot' from 'C:\\Users\\Admin\\AppData\\Local\\
Packages\\PythonSoftwareFoundation.Python.3.9_qbz5n2kfra8p0\\
LocalCache\\local-packages\\Python39\\site-packages\\matplotlib\\
pyplot.py'>
```

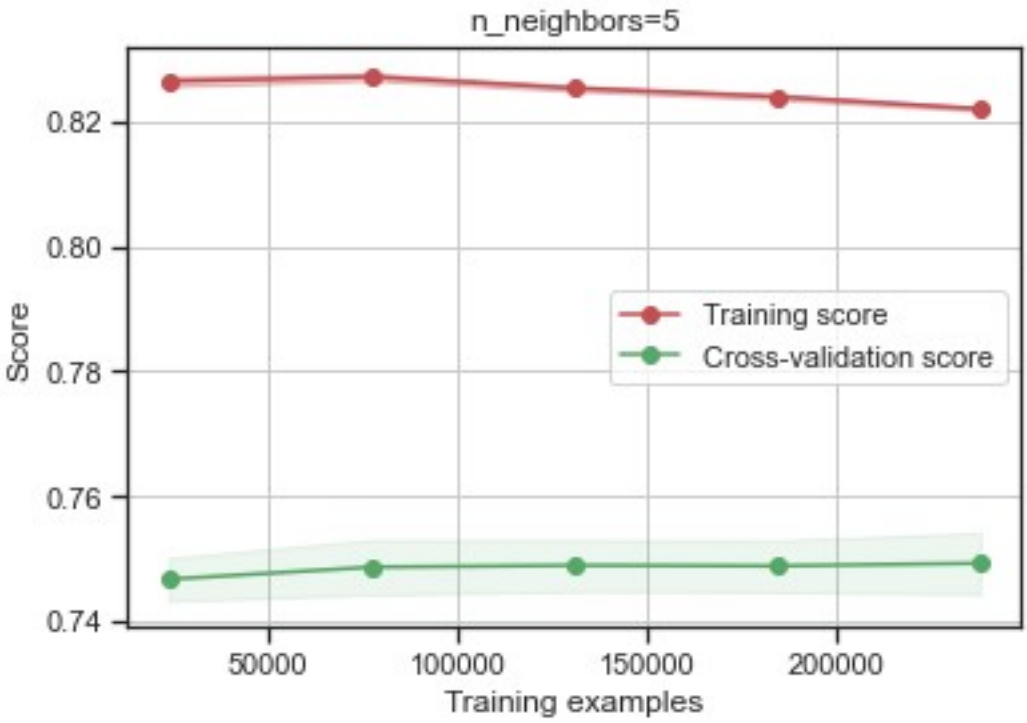
n_neighbors=5
0.82
0.80
0.78
0.76
0.74
Score
Training score
Cross-validation score
50000
100000
150000
200000
Training examples